

场景篇

AI核心技术与产品场景深度融合

5: 大模型产品开发中的数据准备与

反馈闭环



上节回顾



AI的能力范围

APB

决策式AI

数据
文本
自然语言
代码
公式
图像
音频
视频

数据分析处理

机器学习

预测结果

优化算法

预测模型

结果解释性

金融服务
定价
投资组合
市场预测

交通系统
路线规划
自动驾驶
车辆调度

医疗健康
辅助诊断
预测药物
反应

个性化推荐
推荐排序
推荐内容

生成式AI

生成对抗网络

变分自编码器

对话
文章
代码
图像
视频
音频
数字人
.....

深度学习

强化学习

扩散模型

预训练语言模型

媒体行业
生成物料

电商行业
生成商品图

IT软件
生成代码

客服
生成对话


输入

处理

输出

场景

- 一种新产品在市场推广的过程中，按照用户的接受程度，会分为几类







Part Three

03

四种**Agent**的使用方式

吴恩达 (Andrew Ng)

APB



- Google Xlab
- 百度首席科学家
- Landing.ai CEO
- 亚马逊董事会



- “相比于单纯追求更强的模型（Model-centric），通过设计良好的工作流（Workflows）让大模型像智能体一样工作，能带来巨大的性能提升。即便使用GPT-3.5这种旧模型，如果使用了Agent工作流，其表现甚至能超过GPT-4的零样本（Zero-shot）表现”





- 我们今天先和大家讲这几种模式的目标和差异
- 具体实现细节我们后面课程展开讲





Reflection (反思/自我修正)

APB

- 核心逻辑：不是一次写完就输出，写完后自己检查一遍，找错误，然后修改
- 例如：
 - 原本的做法：
 - 用户：“帮我写一个方案”
 - AI：“好的，方案如下……”
 - Reflection模式：
 - 第一步：AI生成草稿
 - 第二步（反思）：AI自我提问“这个方案有问题么，数据都有来源么？符合用户要求么？”
 - 第三步：AI根据反思结果，重新修正



- 输出 -> 评估 -> 改进
- 构建步骤：
 - Generator (生成器): 负责生成初步内容。
 - Reflector (反思者): 负责扮演“挑剔的批评家”，指出错误。
 - 循环控制器: 将批评意见反馈给生成器，要求重写。



四种智能体模式

APB



- 核心逻辑：
 - 在需要的时候求助于外部工具
- 例如：
 - 原来的做法
 - 用户：“35*8912等于多少”
 - AI：用语言模型预测下一个字，很容易错
 - Tool Use模式
 - AI：这是个精确计算，我需要调用计算器
 - 调用python 代码，输出精准结果
 - 用户“我想知道今天的股价”
 - AI：调用搜索工具-给出结果



- Function Calling /MCP/ReAct
- 构建步骤：
 - 工具定义：
 - 清晰地描述工具的功能、参数（例如：“计算器：接收两个数字，返回乘积”）
 - 路由/选择（Router）
 - LLM 根据用户问题，判断是否需要工具，以及需要哪个工具
 - 执行（Executor）
 - 运行代码或API
 - 解析（Parser）
 - 将工具的返回结果转换回LLM能读懂的语言



四种智能体模式

APB



- **核心逻辑：** 面对复杂任务，不急着手，先拆解步骤，然后一步步执行
- 例如：
 - 原来的做法：
 - 帮我写一个俄罗斯方块游戏
 - AI “吐出一堆代码，结构混乱，很可能写到一半断掉”
 - Planning模式
 - **第一步（思考）：** “要写个游戏，我需要：1. 设计UI，2. 写游戏循环逻辑，3. 处理键盘输入，4. 写结束判定。”
 - **第二步：** “现在我先写第一步UI...”
 - **第三步：** “第一步完成了，现在依据第一步的结果写第二步...”



✓ **Style Recommendations**

Get style recommendations for children's book illustrations that are colorful, simple, and age-appropriate for 2-year-olds

✓ **ChatGPT Image**

Generate all character designs in a consistent style: the little cat (protagonist), squirrel, duck, elephant (friends), and fox (antagonist). Each character should be simple, colorful, and appealing to 2-year-olds.

✓ **ChatGPT Image**

Generate the first set of story illustrations (pages 1-5): 1) Little cat playing happily, 2) Little cat meeting friends (squirrel, duck, elephant) 3) Little cat and friends playing together, 4) Fox watching from distance, 5) Fox approaching little cat when alone

✓ **ChatGPT Image**

Generate the second set of story illustrations (pages 6-10): 6) Fox offering something to little cat, 7) Little cat looking unsure/hesitant, 8) Little cat remembering safety rules, 9) Little cat running to find friends, 10) Friends protecting little cat from fox

✓ **ChatGPT Image**

Generate the final set of story illustrations (pages 11-15): 11) Fox leaving disappointed, 12) Friends praising little cat for being smart, 13) Little cat learning lesson about stranger danger, 14) Little cat and friends playing safely together, 15) Bedtime scene with little cat feeling safe

✓ **End**

Complete the task by providing a summary of the children's picture book created

- 关键步骤:
- Smart Plan
 - 确定风格
 - 设定主要角色
 - 故事梗概
 - 图片制作



- 核心原理： 拆解（Decomposition）与 状态管理。
- 构建步骤：
 - Planner（规划者）： 只负责把大目标拆解成 [Step 1, Step 2, Step 3] 的列表，不做具体执行
 - Worker（执行者）： 领取当前步骤的任务去执行
 - Updater（更新者）： 每做完一步，更新剩余的任务列表



四种智能体模式

APB



- **核心逻辑：** 一个AI分饰多角，或者多个AI各司其职，通过“挑战”或“合作”把事情做好
- **原来的做法：**
 - 一个全能AI试图解决所有问题。
- **Multi-agent模式：**
 - 角色A（产品经理）：“我要一个俄罗斯方块游戏，要求界面复古。”
 - 角色B（程序员）：“好的，我写好了代码。”
 - 角色C（测试员）：“我运行了一下，发现碰到墙壁不会死，请B重写。”
 - 角色B（程序员）：“收到，正在修复...”



这个步骤的核心逻辑

APB

- 类似于人类分工逻辑
- 一个心理专业的人进行核心文案创作
 - 负责内容的专业性
- 一个自媒体视频编导进行分镜输出
 - 负责视频内容符合平台调性
 - 负责流量



- 基于原本业务链路人的分工系统
- 或者流程分工，进行 workflow 规划
- 之后再考虑合并优化



- 核心原理： 角色扮演（Role Playing）与 消息传递（Message Passing）。
- 构建步骤：
 - 定义角色（Persona）： 给每个Agent设定专有的System Prompt（如“你是一个资深Python程序员，只写代码，不写文档”）
 - 定义流程（Flow）
 - 终止条件： 什么时候停止？（比如：测试说“ok”，或者主管说“批准”）。



四种智能体模式

APB



CONTENTS

目录

01

从推荐算法看数据对产品的壁垒价值

02

产品经理在微调上的策略选择

03

如何在用户使用中更好的获取提升数据



Part One

01

从推荐算法看数据对产品的壁垒价值


构建一个AI产品的步骤

APB



构建一个AI产品的步骤

APB



- 一个真正持续运营的AI产品
- 上线不是结束，而是进入了一个新的阶段
- 开始进入冷启动阶段
- 真正在线上用真实数据和反馈优化自身




- 如何构建一个推荐产品



第一种方式：内容相似度

APB

让子弹飞 (2010)



导演: 姜文
编剧: 朱苏进 / 述平 / 姜文 / 郭俊立 / 危笑 / 李不空 / 马识途
主演: 姜文 / 葛优 / 周润发 / 刘嘉玲 / 陈坤 / 张默 / 姜武 / 周韵 / 廖凡 / 姚橹 / 邵兵 / 苗圃 / 冯小刚 / 胡军 / 马珂 / 白冰 / 杜奕衡 / 李静 / 胡明 / 危笑 / 杨奇雨 / 赵铭
类型: 剧情 / 喜剧 / 动作 / 西部
制片国家/地区: 中国大陆 / 中国香港
语言: 汉语普通话 / 四川话 / 山西话
上映日期: 2010-12-16(中国大陆)
片长: 132分钟
又名: 让子弹飞一会儿 / 逃子弹
IMDb: tt1533117
官方小站: [让子弹飞](#)

一步之遥 (2014)



导演: 姜文
编剧: 姜文 / 郭俊立 / 王朔 / 廖一梅 / 述平 / 更多...
主演: 姜文 / 葛优 / 周韵 / 舒淇 / 文章 / 更多...
类型: 剧情 / 喜剧 / 动作
制片国家/地区: 中国大陆 / 美国 / 中国香港
语言: 汉语普通话 / 英语 / 上海话 / 法语 / 日语 / 满语 / 越南语 / 拉丁语
上映日期: 2014-12-18(中国大陆)
片长: 140分钟
又名: 随子弹去 / Gone With The Bullets
IMDb: tt2353715
[《一步之遥》专题页](#)

很容易感觉哪两个内容更相似
为什么?

上海堡垒 (2019)



导演: 滕华涛
编剧: 滕华涛 / 韩景龙 / 江南
主演: 鹿晗 / 舒淇 / 石凉 / 高以翔 / 王宫良 / 更多...
类型: 爱情 / 科幻 / 战争
制片国家/地区: 中国大陆
语言: 汉语普通话
上映日期: 2019-08-09(中国大陆)
片长: 107分钟
又名: Shanghai Fortress
IMDb: tt6628322

Wakanda Forever (2022)



导演: 瑞恩·库格勒
编剧: 瑞恩·库格勒 / 乔·罗伯特·科尔
主演: 莱蒂希娅·赖特 / 露皮塔·尼永奥 / 丹娜·奎里拉 / 温斯顿·杜克 / 安吉拉·贝塞特 / 更多...
类型: 剧情 / 动作 / 科幻 / 惊悚 / 奇幻 / 冒险
制片国家/地区: 美国
语言: 英语 / 科萨语 / 玛雅语 / 法语
上映日期: 2023-02-07(中国大陆) / 2022-11-09(中国台湾) / 2022-11-11(美国)
片长: 161分钟
又名: 黑豹: 瓦坎达万岁 / 黑豹2: 瓦坎达万岁(港/台) / Black Panther 2 / Black Panther II
IMDb: tt9114286

相似性如何分析

APB

- 第一步：给内容打标签
 - 导演
 - 主演
 - 类型
 - 编剧
 - 原作者
 - 风格
 - 时代背景
 -




- 将标签向量化，并给出不同权重
- 例如：
 - 电视剧有可能主演的权重更高
 - 电影有可能导演的权重更高
 - 如果原作者是知名作者，则给以给出更高权重
 -



- 第三步：通过向量，用数学方式计算两个向量的相似度
- 常用的相似度公式有比较多：
 - 余弦相似度（常用）：两个向量之间的夹角越小，则两个向量越相似
 - 欧几里德距离（常用）：多维空间中各点之间的绝对距离，越近越相似
 - 皮尔逊相关系数：变量之间线性相关程度
 - Jaccard相似度：文本A与文本B中交集的字数除以并集的字数



- 第四步：基于相似度范围，进行推荐
- 找到与当前 内容 最相似的一批 内容，即可组成一个群体进行推荐
- 找到群体的方法：
 - 通过上一步，我们知道了内容之间的相似度
 - 把相似度当做内容之间的距离，让内容散落在平面上
 - 以当前内容A为圆心，设定半径为K的圆（K可调）
 - 落在圆内的内容，就是内容A的相似群体




基于属性的相似度推荐

APB

- 基于内容属性相似度的推荐：

根据内容之间的相似度，把与内容1相似的内容3，推荐喜欢内容1的用户A



- 优点：
 - 用户之间独立性，每个用户的推荐都是自身所获得的
 - 非常好的可解释性
 - 可以快捷冷启动
- 缺点：
 - 并不根据用户的个性化特征进行推荐，准确度一般
 - 只要采用这个算法，结果高度趋同，除了权重之外没有壁垒性



- 如果大模型产品开发
- 单纯依靠prompt，也是没有产品价值壁垒的
- 通过独特的知识库数据带来的有一定的差异性
- 但如果知识库可以基于用户的使用进行更新，则会形成增强回路
- 极大的提升用户体验



通过AI形成增强回路

APB



用户越使用，越精准
越精准，体验越好
构成体验的壁垒



算法进化：第一段，引入用户属性相似度

APB

用户画像

内容画像



算法进化：第一段，引入用户属性相似度

APB

- 静态画像：

地域、性别、年龄、

学历、收入.....

用户画像


内容画像



增加基于用户相似度的推荐

APB

- 根据用户之间的相似度，把用户B喜欢的内容推荐给与ta类似的用户A



- 通过用户相似度，开始出现用户“部分个性化”效果
 - 冷启动阶段收集用户基础信息和偏好
 - 通过用户近似度推荐给出更精准内容



算法进化：第二段，引入动态画像

APB

- 静态画像：

地域、性别、年龄、
学历、收入.....

- 动态/行为画像：

看过、点赞、收藏、
转发、评论.....

用户画像

内容画像

- 静态画像：

分类、标签、聚类

- 动态画像：

观看量、完播率、
点赞率、转发率.....



- 协同过滤是利用“集体智慧”进行推荐的方法，对用户/内容，找到ta的相似性群体（邻居），并根据这个群体的情况来进行推荐
- 协同过滤是推荐算法中最基本的算法，也是应用最广的算法
- 分为：
 - 基于用户的协同过滤
 - 基于内容的协同过滤



- 通过用户的行为去寻找与其相似的用户进行推荐
- 与基于用户属性相似度推荐相比，核心区别是计算相似度的定义不同
 - 属性推荐：比较多的考虑用户的静态、偏静态的属性
 - 协同过滤：除了静态属性，还比较多的考虑用户历史行为偏好
- 协同过滤包含两步偏好：
 - 用户相似度
 - 用户与内容之间的行为偏好关系




举个例子

APB




举个例子

APB



举个例子


APB



这个数据怎么得来的：
通过观看、完播、评论、点赞等行为
进行计算


举个例子

APB



举个例子

APB



- 通过用户对内容的行为偏好，找到与用户喜欢内容相类似的内容进行推荐
- 简单地说：喜欢A的用户大多也喜欢B
- 同样的包含两步偏好：
 - 用户产生过偏好行为的内容评价分
 - 内容之间的相似度




基于内容相似度的协同过滤

APB



基于内容相似度的协同过滤


APB



内容相似度的权重升级
除了静态画像相似度之外
引入动态相似度
例如：同样的标签的3个剧
A和B的完播，转评赞都很高
但C的评分和弯玻璃极低
则C和AB的相似度会被逐渐修订为低

基于内容相似度的协同过滤

APB



协同过滤的优缺点

APB

- 优点：
 - 不依赖于内容的理解，可跨内容载体实现推荐
 - 结果可解释
- 缺点：
 - 马太效应，往往少部分用户行为或内容能够影响很大范围的推荐结果。e. g：出现一部热剧，就哪儿哪儿都是它
 - 新内容冷启动慢
 - 数据容易受到污染（刷数据、作弊等行为）



第三次升级：隐语义模型

APB

- 利用机器学习的方法，挖掘用户、内容、用户历史行为偏好之间的关系，从而基于用户的偏好找到用户可能感兴趣的内容
- 深度学习的推荐算法有很多，我们简化的来了解一个比较经典的模型：

基于隐语义的模型推荐（LFM）



- 根据用户的属性和历史行为，我们可以绘制一张 用户/内容 的大表，来表示用户对内容的偏好程度（此表我们叫做原始矩阵）

	内容1	内容2	内容3	内容4	内容5	内容6
用户1	0.9		0.3	0.81	0.45	0.3
用户2	0.6	0.8	0.2			
用户3	0.9		0.3			0.5
用户4		0.2		0.6		
用户5		0.68			0.25	
用户6			0.54			0.33
用户7	0.7			0.4		

- 首先根据行为对用户的偏好进行分类
 - 例如：有人喜欢看美女，有人喜欢听鸡汤，有人喜欢国际内容，有人从不看1分钟以上的，有人对带货敏感，有人对秒杀积极……
- 同样的，内容也可以按照这些用户偏好来进行分类



- 首先把用户的兴趣偏好进行分类
- 同样的，内容也可以按找这些用户偏好来进行分类
- 得到两个关系矩阵：

	偏好1	偏好2	偏好3
用户1		0.23	0.77
用户2	0.45	0.1	
用户3	0.38		0.3
用户4			0.85

	偏好1	偏好2	偏好3
内容1	0.15	0.78	
内容2	0.39		0.46
内容3			0.8
内容4		0.5	

	偏好1	偏好2	偏好3
用户1		0.23	0.77
用户2	0.45	0.1	
用户3	0.38		0.3
用户4			0.85



	偏好1	偏好2	偏好3
内容1	0.15	0.78	
内容2	0.39		0.46
内容3			0.8
内容4		0.5	

- 通过矩阵计算的方法合成 用户-内容 完整矩阵，从而得知 内容对用户的推荐分数
- 系统过程：
 - 首先随机生成初始矩阵
 - 进行矩阵计算，要求推荐的结果要与原始矩阵中已有的数值尽可能的接近
 - 通过机器学习的方法，不断寻求最优解



- 一个AI类产品
- 初始阶段需要考虑冷启动问题，尽量在少数据的情况下也能够运转
- 但上线之后就要更多的考虑如何基于用户真实数据修正和提升自己的算法结果
- 这个过程既是提升准确率的过程，也是通过数据建立产品壁垒的过程



构建数据集的步骤

APB

数据收
集

数据筛
选

数据合
成

数据格
式化



- 从客户、需求方收集相关语料
- 例如：
 - 如果构建一个心理医生的智能体
 - 收集医患交流的QA对



- Q:我在感情上很混乱，最近发现他的前女友也是我的熟人
- A:听说这种事情很难处理，不要太沉迷，要有自己的生活和兴趣爱好
- Q:但我不知道该怎么面对他
- A:可以跟他好好谈一谈，让他知道你对这件事的感受
- Q:我总是无法入睡，整晚躺在床上想。
- A:这是一种焦虑症状，试着换个环境，放松自己，深呼吸一下。
- Q:我总是觉得没人理解我。
- A:我理解你的心情，想找个人诉说是可以的，但也要有自己的节奏。
- Q:我有点担心自己的心情。
- A:尽快寻求专业帮助，不要把负面情绪压抑在内心。
- Q:我感觉自己很疲倦，没有前进的动力。
- A:这是一种情绪低落的表现，找个目标去实现、做些轻松愉快的事情也能改善心情。



- 主要指去除无效、不合格的数据
- 这一步一般由业务专家来完成



- 当语料的数据量、丰富度不足时
- 可以让LLM根据已有语料生成更多的数据来补足数据



- 每种训练方法和框架对数据格式都有一定要求
- 最后需要形成同一个格式



- Q:我在感情上很混乱，最近发现他的前女友也是我的熟人
- A:听说这种事情很难处理，不要太沉迷，要有自己的生活和兴趣爱好
- Q:但我不知道该怎么面对他
- A:可以跟他好好谈一谈，让他知道你对这件事的感受
- Q:我总是无法入睡，整晚躺在床上想。
- A:这是一种焦虑症状，试着换个环境，放松自己，深呼吸一下。
- Q:我总是觉得没人理解我。
- A:我理解你的心情，想找个人诉说是可以的，但也要有自己的节奏。
- Q:我有点担心自己的心情。
- A:尽快寻求专业帮助，不要把负面情绪压抑在内心。
- Q:我感觉自己很疲倦，没有前进的动力。
- A:这是一种情绪低落的表现，找个目标去实现、做些轻松愉快的事情也能改善心情。



- [{"content": "我在感情上很混乱，最近发现他的前女友也是我的熟人。", "role": "user"},
- {"content": "听说这种事情很难处理，不要太沉迷，要有自己的生活和兴趣爱好。", "role": "assistant"},
- {"content": "但我不知道该怎么面对他。", "role": "user"},
- {"content": "可以跟他好好谈一谈，让他知道你对这件事的感受。", "role": "assistant"},
- {"content": "我总是无法入睡，整晚躺在床上想。", "role": "user"},
- {"content": "这是一种焦虑症状，试着换个环境，放松自己，深呼吸一下。", "role": "assistant"},
- {"content": "我总是觉得没人理解我。", "role": "user"},
- {"content": "我理解你的心情，想找个人诉说是可以的，但也要有自己的节奏。", "role": "assistant"},
- {"content": "我有点担心自己的心情。", "role": "user"},
- {"content": "尽快寻求专业帮助，不要把负面情绪压抑在内心。", "role": "assistant"}]



大模型的原理是什么？

海量阅读

学习搭配

生成回答



- 大模型学习和人类学习的差异

- 人类学习：理解内容本身

- 例如：苹果是什么？

- 是一种水果，圆形的，红色、黄色、绿色，多汁，酸甜，好吃

- 有时也可以是手机和电脑的品牌

- 大模型学习：统计文字间的搭配关系、上下文关系、表达方式

- 例如：天空是_____的

- 大模型发现从海量的学习内容中，最长出现的是“蓝”，但并不理解什么是蓝

- 例如：牛顿

- 大模型发现相关性最高的有“万有引力”、“物理学家”、“苹果”



- 大模型的脑子里是什么？
- 不是百科全书的目录结构
- 而是一张巨大无比且错综复杂的网
- 标识着每个词之间的关系强度
- 所谓的神经网络




常见的连接模式

APB

- 词语之间的关联
 - （“苹果”常和“吃”、“水果”、“公司”一起出现）
- 语法规则
 - （主谓宾结构）
- 逻辑推理
 - （“因为...所以...”的模式）
- 事实性关联
 - （“巴黎是法国的首都”）
- 写作风格
 - （诗歌、代码、新闻的不同套路）



- 巨型文字拼读
- 根据输入的问题（提示词）
- 从大模型记忆库（统计模型）
- 海量文字碎片中，找到概率上最可能连贯在一起的文字序列
- 然后一个字一个字“拼”出来



- 大模型本身是一种“概率”“关系”逻辑
- 通过微调的QA对，让大模型对基于QA对的“关系”的向量权重更大
- 继而形成微调效果



模型微调的方法

可以在硅基流动上做一些实验

APB



新建微调任务

APB

×

新建微调任务

基础信息

* 任务名称

任务名称

基础模型

Qwen/Qwen2.5-7B-Instruct

微调训练价格：¥ 3.5 / M tokens

微调推理价格：¥ 0.53 / M tokens

* 微调数据集

验证数据集

训练数据集

10

%

作为验证集

指定验证数据集

* 微调模型名称

ft:LoRA/{model_name}-{uid}: 自定义模型名称 :{uid}-{ckpt}-{steps}



上传 Jsonl 文件



拖拽文件到此区域上传，或 点击上传

仅支持 .jsonl 文件，且需符合以下要求：

1. 每行是一个独立的 JSON 对象；
2. 每个对象须包含一个键名为 messages 的数组，数组不能为空；
3. messages 中每个元素必须包含 role 和 content 两个字段；
4. role 只能是 system、user 或 assistant；
5. 如果有 system 角色消息，应在数组首位；
6. 第一条非 system 消息必须是 user 角色；
7. user 和 assistant 角色的消息应当交替、成对出现，不少于 1 对；
8. 数据集不超过5000行。如有更大数据集，请[联系我们](#)。

确认

```
{
  "id": 0,
  "normalizedTag": "婚恋",
  "messages": [
    {
      "role": "system",
      "content": "你是一位精通理情行为疗法（Rational Emotive Behavior Therapy, 简称REBT）的心理咨询师"
    },
    {
      "role": "user",
      "content": "晚上好，我最近心里有些不太舒服，和男朋友的事情让我很苦恼。"
    },
    {
      "role": "assistant",
      "content": "晚上好，我在这里倾听你想要分享的一切。你能具体讲讲是什么事让你这么苦恼吗？"
    },
    {
      "role": "user",
      "content": "我和男朋友谈了4年了，但他一直不同意把工资卡交给我管理，这让我感到很不安。"
    },
    {
      "role": "assistant",
      "content": "这个问题看起来对你来说很重要，也很让你感到挫败。你能告诉我更多关于你的感受吗？"
    },
    {
      "role": "user",
      "content": "每次我提到这件事，他总是以各种理由拒绝我，我真的不明白，难道他不信任我吗？"
    }
  ]
}
```

Notion Ca

Part Two

02

产品经理在微调上的策略选择

确定是否
微调

选择微调
方法

确定技术
路线图

数据准备



确定是否
微调

选择微调
方法

确定技术
路线图


数据准备



- 不是所有项目都适合微调
- 不要认为模型效果不好就必须微调
- 微调是一个成本高，确定性相对低的工具



类型	微调方案	RAG方案
响应延迟	无影响	增加5%-15%耗时
计算成本	高 (训练成本)	低 (仅索引更新)
实施复杂度	高	中 (需要一定的开发和基础设施)
可解释性	中低 (黑盒更新)	高 (可追踪文档)



输出准确
性

Prompt工
程的限制

成本的长
期平衡



- 很多论文的实验结果，表明微调过的模型比不微调的模型在企业专属数据集的测试当中，准确率会有 10% 左右的提升
- 在商业领域10%会有至关重要的决定性结果



- Prompt+RAG固然能解决一部分问题
- 但是prompt窗口是有长度限制的
- 越长的Prompt，大模型的推理成本越高，因为推理成本是跟Prompt长度的平方正向相关的
- Prompt太长会因超过限制而被截断，进而导致大模型的输出质量打折



- 用RAG 还是用微调，核心选择逻辑
 - 业务本身需求是知识性的还是服务性的
 - 对更新频度的要求（高频用rag）
 - 成本要求（看短期和长期的共同判断）
 - 技术能力和条件



- 是AI完全答不上来
 - 能力问题
- 答得不对但沾点边
 - 知识问题
- 答案没错但语气风格不对
 - 风格问题



明确需要微调的场景一

APB

- 你的场景需要模型具备某种“新能力”，而不只是“新知识”
- 比如
 - 让AI学会特定格式的数据分析报告生成
 - 掌握某种专业领域的推理方法
- Prompt工程通常效果有限
- 因为通用模型本身可能就不具备这种专项能力



明确需要微调的场景二

APB

- 需要模型在”风格一致性”上达到极高标准
- 比如
 - 品牌客服机器人，需要严格遵循品牌调性；
 - 法律文书生成，格式和措辞高度规范性
- 单纯靠Prompt描述风格，效果不稳定



明确需要微调的场景三

APB

- 需要在用户端部署模型，或者对响应速度有极高要求
- 调用API可能延迟太高或者成本高
- 微调一个小模型本地化部署



- 当业务量小的时候，通用大模型有明显优势
 - 尽管每次使用的token成本高，但没有前置成本
- 但当业务量足够大，累计的tokens额外费用超过了前置成本累计，就是另外一个情况了



- RAG
 - 优势
 - 快速引入最新知识
 - 更新起来很方便
 - 缺点
 - 推理能力有限
 - 复杂逻辑处理不了
- 微调正好相反
 - 能提升模型的推理能力和风格控制，但知识更新麻烦



- 先用RAG解决知识更新问题，再用微调优化回答风格和推理能力
- 例如：
 - 客服系统
 - RAG解决产品手册
 - 微调解决风格化和推理



确定是否
微调

选择微调
方法

确定技术
路线图

数据准备



- 监督式微调SFT(Supervised Fine Tuning)
 - 用人工标注的数据，用传统机器学习中监督学习的方法，对大模型进行微调
- 基于人类反馈的强化学习微调RLHF(Reinforcement Learning with Human Feedback)
 - 把人类的反馈，通过强化学习的方式，引入到对大模型的微调中去，让大模型生成的结果，更加符合人类的一些期望
- 基于AI反馈的强化学习微调RLAIF(Reinforcement Learning with AI Feedback)
 - 这个原理大致跟RLHF类似，但反馈的来源是AI
 - 收集人类反馈，相对来说成本会比较高



- Prompt Tuning

- 基座模型 (Foundation Model) 的参数不变，为每个特定任务，训练一个少量参数的小模型，在具体执行特定任务的时候按需调用

- Prefix Tuning

- Prefix Tuning的出发点，跟Prompt Tuning的是类似
- Prompt Tuning是在Embedding环节，往输入序列X前面加特定的Token
- 而Prefix Tuning是在Transformer的Encoder和Decoder的网络中都加了一些特定的前缀



- LoRA

- 背后有一个假设：我们现在看到的这些大语言模型，它们都是被过度参数化的。而过度参数化的大模型背后，都有一个低维的本质模型
- 大模型中有其中一部分参数，是非常重要的，是影响大模型生成结果的关键参数，这部分关键参数就是上面提到的低维的本质模型
- 冻结预训练好的模型权重参数，然后在每个Transformer块里注入可训练的层，由于不需要对模型的权重参数重新计算梯度，所以，大大减少了需要训练的计算量



- 计算资源

- GPU数量
- 型号
- 能跑多久

- 全参数微调一个大模型，可能需要几十上百张高端显卡跑好几天；而LoRA微调，可能一张消费级显卡几个小时就够了。这中间的成本差距可能是几百倍



- 数据资源
 - 数量
 - 质量
 - 标注成本
- 另外
 - 时间成本
 - 团队能力



- 从LoRA做起
- 全参数微调只适用于
 - 对性能要求极高的业务
 - 金融风控
 - 医疗诊断
 - 领域差异极大的场景
 - 分子结构预测
 -



确定是否
微调

选择微调
方法

确定技术
路线图

数据准备




评估需求和资源	任务高度专业化，数据非常充足	资源是否极度缺少	需要快速适配多个任务	需要对齐复杂人类偏好
	例如：专业医疗分析，几十万样本	例如：单张消费显卡，数据量少	例如：多场景助手	例如：高安全需求，情感理解
	全参数微调	QLoRA	LoRA	指令微调+DPO
	核心业务值得大资源投入	最低资源要求，最低成本	灵活，加载不同任务适配器	满足潜在需求

确定是否
微调

选择微调
方法

确定技术
路线图

数据准备



好数据的标准

APB

- 各种场景的数据标准不同
- 客服的好数据
 - 多轮对话
 - 情绪理解
 - 问题解决
- 创作助手
 - 风格化
 - 风格多样性
 - 创意性
 - 表达流畅性





- 数据必须和你的目标场景高度相关
- 不要为了数据量降低相关性
- 例如:
 - 微调法律助手模型
 - 数据里混了大量闲聊对话
 - 结果模型学了一堆没用的东西
 - 微调失败



- 数据要覆盖你场景中的各种情况，不能有偏科
- 比如做电商客服模型
 - 不能只收集咨询产品功能的数据
 - 还要有
 - 投诉处理
 - 退换货
 - 售后维修
 - 等各种场景的数据




- 数据要能代表真实场景中的常见情况，而不是猎奇
- 别总想着收集那些极端案例，99%的用户问题都是常规问题
- 把常规问题处理好，用户体验就能提升一大截



- 你的指令要清晰，回复要明确
- 模糊的指令和模棱两可的回复，很容易微调失败
- 比如
 - 帮我写个东西 ——这种指令就太模糊了
 - 模型根本不知道该写什么
 - 而“帮我写一段产品退款申请微信发言，语气礼貌但坚定，包含订单号和退款原因”这样的指令就清晰多了



- 数据里不能有明显的偏见或错误
- 尤其是涉及性别、种族、地域等敏感话题
- 模型会忠实地学习数据中的一切，包括那些你不想要的偏见



- 直接方法：利用现有产品数据
- 例如：
 - 客服系统真实对话
 - 内容平台：大量用户生成内容
- 需要清洗
 - 废话、错误、敏感
 - 机器+人工
 - 算法初步过滤+人工抽样检查



- 主动构造数据
- 大模型“自我指导”
- 模型根据少量种子数据生成大量类似数据
- 需要设计好策略
- 别简单地让模型”给我生成1000条客服对话”
- 分场景、分类型、分难度等级来生成
- 比如先定义10种常见客服场景，每种场景生成100条不同难度的对话



数据量多少是够的

APB

- 对大多数场景，几千条高质量数据足够
- 10000条高质量数据能解决超过90问题
- 即便几百条数据，通过LoRA也能起效
- 先跑起来，看效果，根据结果决定要不要增加数据




Part Three

03

如何在用户使用中更好的获取提升数据

大模型产品的反馈收集机制


APB



总结

人对秩序的需求是追求可预测性、安全感、效率、意义和社会协作的深刻心理驱管理生活、构建社会的基础。然而，健康的心理状态需要在对秩序的需求和对变之间找到平衡。认识到秩序的价值，同时理解其局限，拥抱适度的不确定性，并序，是应对复杂世界的关键。正如哲学家阿兰·德波顿所言：“我们之所以焦虑，们渴望秩序却无法实现它。”学会在秩序与混乱间从容行走，正是内心自由的重要

ⓘ 本回答由 AI 生成，内容仅供参考，请仔细甄别。



• 隐私问题：收集用户反馈需

☹ Annoying

🗨 Want more info

✂ Not convincing

📅 Forgot something

🗨 Too wordy

⊗ Incorrect answer

🗨 Wanted something else

规模反馈处理

(由xAI开发

Hugging Fac

户反馈机制运

同时平衡优化

🔄 📄 📌 👍 🗨 ... 1.6s

反馈

有害/不安全

虚假信息

没有帮助

其他

我们想知道你对此回答不满意的原因，你认为更好的回答是什么？

取消

提交

反馈收集层

- 用最简单的交互方式收集用户反馈（点赞、点踩）
- 点击后给出更多信息（具体原因）
- 重生成时记录用户选择的更好回答

数据处理层

- 建立反馈质量评分模型（0-1分）
- 构建对比数据集（好的回答vs 差的回答）

模型优化层

- 训练奖励模型预测人类偏好
- 通过算法优化主模型
- 每月一次大规模更新，关键问题热修复



行业价
值

行业现
状和痛
点

行业发
展态势

大模型
能力结
合点

需求分
析

架构搭
建



结合场景分析和拆解需求

APB

- 业务查询
- 业务答疑
- 办理退款
- 取消业务
- 涉政/涉黄敏感处理
- 未知业务
- 闲聊






你们这个保险不是达州的户口，可以买吗？



无论户口所在地在哪里，只要您是达州市医保参保人（含城镇职工、城乡居民）、已参加异地基本医保的达州市户籍人员或者持有达州市居住证且已参加异地基本医保的达州市新市民，都可以参保的。

- 大模型思考：知识库能解答，我来回答，我不
用ask human





- 大模型思考：知识库不能解答，需要ask human help
- human回答的这个知识点我要记录下来，下次就知道怎么回复啦
- 注意，这里面AHH不是简单的转人工，而是人工处理信息，进入RAG


微调vs RAG如何选择

APB

- 用户反馈应用模型微调还是RAG
- 需要综合考虑几个要素
 - 更新频率
 - 问题类型
 - 成本考量




• 技术实现的路径对比




- 一个基于大模型的智能客服系统
- 用户反馈可能的问题
 - 知识性错误
 - 政策输出问题
 - 商品信息问题
 - 语气态度问题
 - 态度不合适
 - 没有对用户情绪做识别
 - 服务流程问题
 - 推荐准确度
 - 退费等处理处理逻辑问题



问题类型	处理方式	生效时间	技术实现
知识性错误	RAG更新	1小时以内	知识库修正+向量索引重建
服务流程问题-处理逻辑	workflow修正	1天以内	workflow+意图识别修正
服务流程-推荐准确度	模型微调+算法	周左右	算法优化
语气态度问题	微调+prompt	周左右	RLHF+风格转换





- PPO（近端策略优化）
 - OpenAI 2017年提出的一种策略梯度算法
- 和传统RL的区别，简单来说
 - 教孩子学骑自行车
 - 传统RL：给孩子一辆车，等孩子早晚能学会
 - 容易摔跤（训练不稳定）
 - PPO：扶着后座，慢慢调整手的力度（平滑更新）
 - 让孩子少摔跤学会



- 小步前进原则
 - 每次让策略只微调一点点，避免学偏
- 奖惩原则
 - 用奖励机制告诉AI什么行为好
 - 例如自行车保持平衡+1，摔倒-1
 - PPO会放大高奖励动作的概率，降低低奖励动作的概率，但调整幅度被限制



- 一个基于大模型的医疗问答系统
- 设计关键点
 - 对准确度要求高
 - 医学事实的更新需要通过专家验证
 - 患者隐私数据需要做保护
 - 药物相互作用需要处理



- 对事实类信息的精度要求更高
 - 必须经过专家验证
 - 需要有紧急通道
- 对态度类需求一般或较低
- 对进入知识库的内容需要可回溯和保留证据链




以药物相互作用模块为例


APB



- 反馈本身没有意义，以不同的方式更高效地转化和利用反馈中隐藏的信息，才使反馈有了意义
- 什么是反馈
 - $\text{Feedback} = \text{Feeding}(\text{数据}) + \text{Understanding}(\text{信息}) + \text{Backing}(\text{执行})$







- 通过运营人员、AI数据工程师在例行问题的分析和标注
 - 基于周、月为单位
- 基于分析结果、将相关信息
 - 优化后的AI数据集
 - 意图判断
 - QA对
- 传递给大模型和工作流，进入下一次的迭代




• AI搜索引擎



- AI搜索引擎应该如何优化
- 标注反馈机制
 - 和常规的搜索引擎类似
 - 将每天最大量的搜索，运营人员判断是否为bad query
 - 给出相应的上报
- 机制的特点
 - 有明确的问题焦点





- 根据业务活动中的上下文信息
- 结合历史知识、经验，生成推荐方案的output
- 业务人员在操作过程中结合实际情况和知识储备
- 采用“完全采纳”、“部分采纳”、“弃用”、“补充”等策略
- 系统提交后进入到下一个环节



例如：彩云小梦

APB

加班，加班，又是那个该死的客户，临时改需求，还必须今天给出来新的方案，已经11:54分了，张峰终于满身疲惫的坐上车，揉了揉眼睛，准备回家。

照例把导航打开，这个时候肯定是一路通畅，12:00整，车，开了。

突然间一阵阴风吹来，让张峰不由的打了个寒战，车里，除了他之外还有一位女孩，正闭目养神。

她穿了件白色长款羽绒服，黑发披肩，脸蛋小巧精致，一双眼睛紧闭着，睫毛在脸上投下了淡淡的暗影。

张峰看了看四周

撤回

修改

继续

加班，加班，又是那个该死的客户，临时改需求，还必须今天给出来新的方案，已经11:54分了，张峰终于满身疲惫的坐上车，揉了揉眼睛，准备回家。

照例把导航打开，这个时候肯定是一路通畅，12:00整，车，开了。

但当他把车子驶向自己居住小区的大门口时，忽然发现前方的路不对劲，怎么黑乎乎的，像是没有路灯的夜晚？

"滴....."

车轮碾过地面，发出的刺耳声音，让张峰猛地从椅子上弹起来，紧接着，一辆大卡车朝他的车撞来！

"轰.."

撤回

修改

继续

没有满意的？

换一批

点击其他卡片看一看

突然间一阵阴风吹来，让张峰不由的打了个寒战，车里，除了他之外还有一位女孩，正闭目养神。

她穿了件白色长款羽绒服，黑发披肩，脸蛋小巧精致，一双眼睛紧闭着，睫毛在脸上投下了淡淡的暗...

但当他把车子驶向自己居住小区的大门口时，忽然发现前方的路不对劲，怎么黑乎乎的，像是没有路灯的夜晚？

"滴....."...

然而这一次，张峰没想到自己竟然开错了。

车行驶在高速路上，忽然，一阵急促的刹车声传来，张峰的身子猛地向前扑去，惯性作用下，他的脑袋狠狠撞在了玻璃窗上，一阵疼痛袭来，让他瞬间清醒...

伍

👤 基本信息

图片链接

求职意向

产品经理

邮箱	主页链接
example@mail.com	https://example.com

电话 城市

+ 添加自定义字段

个人总结

5年产品经验，专注于电商领域，擅长用户研究和数据分析

社交主页

张三

产品经理

☎ 13800138000 @ example@mail.com

个人总结

5年产品经验，专注于电商领域，擅长用户研究和数据分析

工作经历

爱奇艺 2018-05-2021-05

产品总监

负责爱奇艺短视频App“Nani”的产品规划、设计和迭代，旨在打造年轻用户喜爱的短视频社区。

职责描述:


- 负责用户调研，深入了解年轻用户对短视频内容的需求和偏好。
- 撰写产品需求文档（PRD），详细定义产品功能、用户流程和交互设计。
- 协调开发、设计、运营团队，确保产品按计划高质量上线。
- 分析用户数据，监控产品表现，并根据数据反馈进行快速迭代。

成果:

- “Nani” App上线后，用户日活（DAU）增长了30%，用户平均使用时长提升了20%。
- 成功策划并推出了5个爆款短视频话题，吸引了大量用户参与和创作。
- 用户对App的整体满意度评分达到4.5/5，在同类产品中处于领先地位。

经验/教训:

- 深入了解年轻用户需求是打造成功短视频产品的关键。
- 快速迭代和数据驱动的产品开发模式能够有效提升用户体验。
- 跨部门协作和高效沟通是确保产品按计划上线的保障。
- 在竞争激烈的短视频市场，差异化定位和创新功能是吸引用户的关键。




- 业务受众面广，根据用户行为建立反馈收集机制
- 根据业务特点，判断用户行为的意图
- 核心在于用户行为的感知和分析



例如

APB



这个数据怎么得来的：
通过观看、完播、评论、点赞等行为
进行计算

例如：midjourney

APB



- 显性标注：
 - 生成图面下面的Favourit（喜欢或收藏）
- 隐性标注：
 - 刷新：推测用户都“不喜欢”
 - 以某一张为基础，再生成四张：推测对这张的喜欢高于其他
 - 做了n次刷新和生成，选择了一张图片做了放大：推测这张是满意的

- 由于在没有利益驱使的状态下，没有人默认要进行反馈
- 在用户的正常交互中，增加隐性反馈机制
- 同时根据隐性反馈机制的日志详细分析用户意图，根据意图进行行为反馈是更好的方式





Part Fore

04

总结

构建一个AI产品的步骤

APB



通过AI形成增强回路

APB



用户越使用，越精准
越精准，体验越好
构成体验的壁垒




基于属性的相似度推荐

APB

- 基于内容属性相似度的推荐:

根据内容之间的相似度，把与内容1相似的内容3，推荐喜欢内容1的用户A



算法进化：第二段，引入动态画像

APB

- 静态画像：

地域、性别、年龄、
学历、收入.....

- 动态/行为画像：

看过、点赞、收藏、
转发、评论.....

用户画像

内容画像

- 静态画像：

分类、标签、聚类


- 动态画像：

观看量、完播率、
点赞率、转发率.....



举个例子

APB



第三次升级：隐语义模型

APB

- 利用机器学习的方法，挖掘用户、内容、用户历史行为偏好之间的关系，从而基于用户的偏好找到用户可能感兴趣的内容
- 深度学习的推荐算法有很多，我们简化的来了解一个比较经典的模型：

基于隐语义的模型推荐（LFM）



反馈收集层

- 用最简单的交互方式收集用户反馈（点赞、点踩）
- 点击后给出更多信息（具体原因）
- 重生成时记录用户选择的更好回答

数据处理层

- 建立反馈质量评分模型（0-1分）
- 构建对比数据集（好的回答vs 差的回答）

模型优化层

- 训练奖励模型预测人类偏好
- 通过算法优化主模型
- 每月一次大规模更新，关键问题热修复



确定是否
微调


选择微调
方法

确定技术
路线图


数据准备



• 技术实现的路径对比




问题类型	处理方式	生效时间	技术实现
知识性错误	RAG更新	1小时以内	知识库修正+向量索引重建
服务流程问题-处理逻辑	workflow修正	1天以内	workflow+意图识别修正
服务流程-推荐准确度	模型微调+算法	周左右	算法优化
语气态度问题	微调+prompt	周左右	RLHF+风格转换



- 反馈本身没有意义，以不同的方式更高效地转化和利用反馈中隐藏的信息，才使反馈有了意义
- 什么是反馈
 - $\text{Feedback} = \text{Feeding}(\text{数据}) + \text{Understanding}(\text{信息}) + \text{Backing}(\text{执行})$





- 暂无
- 微调练习将在个人agent一节配合其他知识点进行练习



- 2-5 大模型产品开发中的数据准备与反馈闭环



智在必得

Thanks for having you all the way

