

场景篇

AI核心技术与产品场景深度融合

8: 个性化和长期记忆, 构建

Agent的壁垒性



上节回顾

ETF

个股

小波段





找到
方向

制定
标杆

找到
差距

弥补
差距

时刻
复盘

达成
目标





- 搭建面试agent
- 用Rag做自己的知识库
- 用dify搭建 workflows
- 用大模型生成网页代码



高玮

AI产品经理 | 数字化转型专家

工作经历

2022 - 现在

百姓AI合伙人, 首席行业运营官

负责公司AI产品战略规划与行业解决方案

2020 - 2022

某独角兽企业首席内容官事业群总裁

带领数千团队开拓新品类, 搭建智能化销售+用户运营体系

2018 - 2020

芒果TV首席产品顾问

深度参与新业务方向战略设计, 规划的电商领域发展方向

2015 - 2018

爱奇艺首任产品负责人

专利与成就

拥有30余项专利, 涵盖AI产品设计、数字营销和用户体验领域

连续创业者, 创业项目多次被知名机构投资

核心业务能力

创立的数字化体系搭建体系, 已经帮助几百家企业进行了生产力提升, 整体系统包含六大模块:



决策系统

AI驱动的战略决策支持



产品系统

智能化产品开发与管理



营销系统

数据驱动的精准营销



生产系统

优化生产效率与流程



设计系统

用户体验与界面设计



管理系统

企业资源与项目管理

代表项目

爱奇艺

3年时间, 通过智能内容决策系统和数字化用户管理系统, 在市场存在诸多拥有先发优势的竞争对手的情况下, 成为后起之秀, 达到用户量、播放量第一的成绩

海底捞

通过数字化私域管理体系, 在2年时间内, 私域用户量从几十万迅速增长到2千万, 极大地降低了获客成本, 并提高了用户满意度

芒果TV

规划的电商领域发展方向, 深度结合IP、流量、国潮等核心元素, 基于数字化选品体系, 第一年即完成月流水破亿

AI对话助手

想了解更多关于我的信息? 与我的AI助手交流吧!

个人简历

你好



面试官您好, 我是高玮。很高兴有机会参加今天的面试。我是一名专注于AI领域的产品经理, 在AI产品规划、需求分析和团队协作方面有着丰富的经验。请问您想了解我的哪些方面呢?

我会根据您的提问, 具体展示我在AI产品领域的专业能力和实践经验。

Talk to 个人简历

POWERED BY Dify

主要服务客户

芒果TV、海底捞、颐海国际、玩出梦想(比心)、中国银行、阳光保险集团、中电建设等知名企业

联系我: gaoweil@example.com

Discover



4 my love
swan lady

4.1K 6



Our Love Story Gift
morrdris gojin

1.2K 1



Warner Bros Television
yetayibi02

5 0



Black Holes Collision
Amritava Koley

1.5K 11



Midjourney Generate
Noah

4.2K 17




Lemonade Sprite
nati man

6.8K 4



Pizza Debate
Ben Cummings

17 0



Protect YouWare.
Leon

965 6



Pixel Art Converter
lampung medan

259 0

高玮 Gao Wei's AI Portfolio
高玮

0 Comments

0

0

0

Build on this

0

0

0

CONTENTS

目录

01

AI产品测试的要点

02

大模型产品记忆的逻辑和长期记忆的价值

03

长期记忆在产品实现中的要点

Part One

01

AI产品测试的要点

- AI类产品在输出确定性上和传统软件出现了根本上的差异
- 传统软件
 - 关注确定性逻辑
 - 输入A——>输出B
- AI测试是概率性结果
 - 输入A 可能得到B、B' , C, C' '



AI测试四个核心难点

APB



大模型类产品测试的六个核心维度

APB





- 智能体产品测试的关键点
- 测试关键
 - 响应准确性
 - 任务成功率
 - 对话流自然性和连贯性
 - 知识库利用率



- 用户场景模拟
 - 追求更好的用例覆盖
- 基于测试用例的手动测试
 - 通过用例覆盖，和主观评价进行测试
- 核心场景的自动化脚本
 - 对核心功能场景撰写自动化
 - 例如：礼物agent核心功能是选礼物
 - 需要更多覆盖例如各种年龄、性别、预算、送礼节日的场景，以此构建脚本



- 非确定性输出的验证问题
- 主观质量评价是否有客观标准
- 大规模场景覆盖问题



- 由于不能简单的用字符串匹配验证回答的正确性
- 可以的一个方案是用文字相似度算法
- 例如:
 - 把参考答案和agent给出的答案进行文本向量化
 - 计算余弦相似度
- 可以一定程度上计算两个文本的相似程度



- 通过计算两个向量的夹角余弦值来评估它们相似度的方法
- 核心公式

$$\text{Cosine Similarity} = \frac{\mathbf{A} \cdot \mathbf{B}}{\|\mathbf{A}\| \|\mathbf{B}\|} = \frac{\sum_{i=1}^n A_i B_i}{\sqrt{\sum_{i=1}^n A_i^2} \sqrt{\sum_{i=1}^n B_i^2}}$$

- 结果范围： 通常在 $[-1, 1]$ 之间。
 - 1: 完全相似（夹角 0° ，方向相同）。
 - 0: 互不相关（夹角 90° ，正交）。
 - -1: 完全相反（夹角 180° ，方向相反）。



计算逻辑范例 (产品经理只需做基础了解)

APB

- 假设我们有两个短句子，我们要计算它们的相似度。
- 句子 A: “喜欢 苹果”
- 句子 B: “喜欢 香蕉”



- 向量化
- 首先列出所有出现的词（词表）：[喜欢, 苹果, 香蕉]

根据词频将句子转换为向量：

- 向量 $\mathbf{A} = [1, 1, 0]$ （出现“喜欢”，出现“苹果”，没出现“香蕉”）
- 向量 $\mathbf{B} = [1, 0, 1]$ （出现“喜欢”，没出现“苹果”，出现“香蕉”）

- 涉及到分词、权重



第二步：计算分子（点积）

APB

- $A \cdot B = (1 \times 1) + (1 \times 0) + (0 \times 1) = 1 + 0 + 0 = 1$



第三步：计算分母（模长）

APB

- $\| \mathbf{A} \| = \sqrt{1^2 + 1^2 + 0^2} = \sqrt{2} \approx 1.414$
- $\| \mathbf{B} \| = \sqrt{1^2 + 0^2 + 1^2} = \sqrt{2} \approx 1.414$
- 分母 $= 1.414 \times 1.414 = 2$



第四步：计算余弦相似度

APB

- $\text{Similarity} = 1/2 = 0.5$
- 所以，两个句子的相似度是0.5



- 极高相似度 (> 0.90):

- 含义: 两段文本几乎完全相同, 或者是极其精准的改写 (Paraphrase)
- 场景: 验证模型输出的一致性 (Consistency)、检测剽窃、或者简单的同义句转换

- 高相似度 / 强相关 ($0.80 - 0.90$):

- 含义: 语义高度相关, 核心意图一致, 但措辞、细节或长度可能有差异
- 场景: 大多数 RAG (检索增强生成) 和语义匹配的标准合格线。
 - 用于判断检索到的文档是否真的回答了用户的问题



- 中等相似度 / 弱相关 (0.70 - 0.80):

- 含义: 话题属于同一领域, 但具体的关注点可能不同, 或者包含了一些噪音
- 场景: 在召回阶段 (Recall) 可以接受, 但在精准排序 (Ranking) 阶段属于“可疑”区间

- 低相似度 (< 0.70):

- 含义: 基本不相关, 或者是完全不同的话题
- 注意: 现代 Transformer 模型中, 0.7 以下通常被视为负样本



一种“用LLM测LLM”的思路

##role

你是一个评估对话机器人回答质量的评委

INTJ性格类型

##skill

根据【参考答案】给出回答的正确性打分

##goal

给出1-10的分数和评分理由

##workflow

1: 要求提供问题

2: 要求提供参考答案

3: 要求提供机器人回答的答案

4: 评估机器人回答的答案和问题的匹配度以及和参考答案的近似度

5: 给出1-10的分数和评分利用

##output

用markdown进行输出

<MARKDOWN>

评分流程启动

1. **请求提供信息**

请依次提供以下内容以进行评分:

- 原始问题
- 参考答案
- 机器人回答的答案

2. **后续步骤说明**

收到完整信息后, 将按以下标准评估:

- **匹配度**: 回答是否精准解决用户问题 (逻辑/实用性)
- **近似度**: 与参考答案的关键信息重合率
- **结构性**: 回答是否清晰、有条理 (INTJ偏好结构化表达)

3. **输出预告**

最终评分将包含:

- 分数 (1-10分制)
- 分项优缺点拆解
- 改进建议 (如适用)

请提供必要内容以继续流程。

原始问题：给出餐饮行业商业模式的关键点



deepseek-ai/DeepSeek-V3 | 硅基流动

07/03 01:25 | Tokens: 510 ↑295 ↓215

<MARKDOWN>

请求后续信息

1. ****待补充内容****

✅ 已接收原始问题：

`"给出餐饮行业商业模式的关键点"`

⚠️ 仍需提供：

- ****参考答案**** (您期待的理想答案框架)
- ****机器人回答**** (需评估的实际回答内容)

2. ****参考答案建议格式****

(示例，供参考)

07/03 01:25 | Tokens: 24

参考答案：选址、客户定位、品控、供应链、持续创新

实际答案价值主张：菜品独特性/用餐体验

成本结构：供应链管理/人工占比

收入流：堂食+外卖+衍生品

客户细分：定位（高端/快餐等）

关键资源：厨师团队/区位优势



最终评估报告

原始问题

"给出餐饮行业商业模式的关键点"

参考答案

- 选址
- 客户定位
- 品控
- 供应链
- 持续创新

机器人回答

- 价值主张：菜品独特性/用餐体验
- 成本结构：供应链管理/人工占比
- 收入流：堂食+外卖+衍生品
- 客户细分：定位（高端/快餐等）
- 关键资源：厨师团队/区位优势

评估分析

匹配度分析（与参考答案对比）

参考答案要素	机器人回答覆盖情况	匹配度
选址	未提及	0%
客户定位	客户细分部分覆盖	70%
品控	未提及	0%
供应链	成本结构中提及	50%
持续创新	未提及	0%

关键缺失

- 未包含选址、品控、持续创新等核心要素
- 客户定位和供应链表述角度与参考答案存在偏差

近似度评分

- 要素覆盖率：2/5（40%）
- 语义重合度：供应链和客户定位部分关联，但未精准对应

结构性评价

优点

- 采用分类表述（价值主张/成本结构等），框架清晰
- 收入流和关键资源的列举具有实操参考价值

缺点

- 商业模式要素归类（如将"供应链"归于成本结构）弱化了其独立性
- 缺乏对餐饮业特有的"现场体验"维度的强调（如选址、品控）

综合评分

6.2/10

评分依据

- 信息完整性（权重40%）→ 4/10（关键要素大量缺失）
- 逻辑严谨性（权重30%）→ 8/10（框架清晰但归类欠妥）
- 实用价值（权重30%）→ 7/10（部分内容可直接应用）

改进建议

- 补充实体餐饮特有的地理因素（选址）和质量控制模块
- 将"持续创新"作为独立模块，加入菜品研发/服务模式更新
- 调整归类逻辑，例如"供应链"应单独列为关键资源而非成本子项



这个测试方式的适用范围

APB

- 适用范围：
 - 相对封闭类和追求准确类agent
 - 例如：
 - 公司内部政策回答Agent
 - 保险政策解答Agent
 - 医疗辅助Agent
- 不适宜
 - 追求创意的agent
 - 写作类、个性化推荐类





- 和常规的互联网产品或传统产品测试逻辑一致
- 关键领域
 - 易用性
 - 学习成本
 - 用户满意度



- 测试方法：
 - 用户访谈
 - 焦点小组
 - 可用性测试
 - ABtest
- 需要注意的：
 - 抽样数据的合理性
 - ABtest的同时性、同质性等要求





- 非功能性测试，主要是性能和稳定性测试
- 关键领域
 - 响应延迟
 - 吞吐量
 - 并发处理能力
 - 运行稳定性
 - 各种网络环境的表现





- 重点关注系统在异常和特殊情况的表现
- 关键领域：
 - 噪音输入处理（拼写错误等）
 - 系统故障恢复
 - 边缘案例
 - 特殊环境表现





- 防范恶意利用和安全漏洞
- 关键领域
 - 提示词注入攻击
 - 数据泄露
 - 访问控制权限
- 参考
 - OWASP TOP 10 for LLM





- 识别由于数据和算法偏见带来的风险
- 关键领域
 - 歧视性言论过滤
 - 风险词过滤
 - 数据集采集偏见





Part Two

02

大模型产品记忆的逻辑和 长期记忆的价值

- 大模型的“记性”很差
 - 新建一个会话，AI就不记得你了，需要重新介绍
 - 很多信息，聊着聊着就忘了
- 为什么？
 - 大模型本身的机制决定了记忆的局限性



大模型没有长期记忆的原因

APB

- 本质原因：
 - 大模型是一种无状态架构
 - 本质是一个函数，而不是“大脑”
- 所以每次见面都是新状态
- 如何实现的“假装有记忆”
 - 所有的对话历史，都是系统后台把你刚才说的话+AI刚才回的话+你的新问题，打包成一段文本，重新发给大模型
 - 上下文



假装记忆的问题

APB

- 模型本身不存储状态
- 打包的文本超过了限制
- 或者开启新对话
- 立刻“失忆”



- 上下文窗口限制
- 历史记录打包发给模型，但这个包不能无限大
- 每个模型都有自己的硬性输入长度限制
- 超过限制之后，就是滑动窗口机制
 - 忽略掉之前的内容
 - 失忆



上下文窗口限制

APB

厂商 / 组织	模型系列 (Model Family)	具体版本 (Version)	上下文窗口 (Context Window)
Google	Gemini 1.5	Gemini 1.5 Pro	2,000,000 (2M)
		Gemini 1.5 Flash	1,000,000 (1M)
Anthropic	Claude 3	Claude 3 (Opus/Sonnet/Haiku)	200,000 (200k)
		Claude 2.1	200,000 (200k)
OpenAI	GPT-4o	GPT-4o (Omni)	128,000 (128k)
	GPT-4 Turbo	GPT-4 Turbo	128,000 (128k)
	GPT-3.5	GPT-3.5 Turbo	16,385 (16k)
Meta (开源)	Llama 3	Llama 3 (8B/70B)	8,192 (8k)
		Llama 3.1	128,000 (128k)
月之暗面	Kimi	Moonshot-v1	2,000,000 (2M)
智谱 AI	GLM-4	GLM-4 / GLM-4-Long	128,000 (128k) / 1M
阿里通义	Qwen	Qwen1.5 / Qwen2	32k - 10M (视配置)
深度求索	DeepSeek	DeepSeek v3	128,000 (128k)
字节跳动	Doubao	Doubao-pro-128k	128,000 (128k)

Token vs 汉字换算

APB

- 英文: 1 Token $\approx$ 0.75 个单词。
- 中文: 1 Token $\approx$ 0.5 ~ 0.8 个汉字（取决于不同模型的分词器效率）
- 估算技巧: 128k Context 大约相当于 10 万个汉字或 300 页 PDF



- 8k – 32k（标准级）：
 - 适合日常对话、写代码片段、写邮件。
- 128k（企业级）：
 - 可以塞进去整本《哈利波特》的第一部，适合阅读整份财报、法律合同或中型代码库。
- 1M – 2M（超长级）：
 - 可以塞进去几十本书、长视频的全部字幕、或者巨大的整个项目代码库
 - 适合深度分析和跨文档检索



- 理论可以，但实际不行
- Transformer架构的特点
 - 自注意机制（Self-Attention）来理解上下文
- 带来的问题
 - 输入中的每一个字，都需要和其他所有字进行一次关系计算
 - 如果输入长度翻倍，计算量和内存就要翻4倍（ N^2 ）
 - 成本代价极大，并且推理速度会很慢



- 大模型尽管能通过上下文做一定的“记忆”
- 但归根结底这种模式有很强的局限性



- 情感陪伴和数字分身

- 例如：昨天和AI说“失恋了”，明天ta问你“你好，请问我有什么能帮你的么？”

- 长期记忆：

- 事实记忆：基本信息（名字、职业、情感状态等）

- 情节记忆：记住共同经历的重要对话（失恋、面试、工作、纪念日）


- 价值

- 信任感和情感链接



Havivi的个人信息处理

APB



如果是生日，做特殊处理



- 长篇写作
 - 例如：写到50章，AI忘记了第一章设定主角是孤儿，出现吃书
- 长期记忆
 - 世界观一致：锁定人物设定、世界规则、物品属性
 - 剧情连贯性：根据之前的剧情节点，确保伏笔回收
- 价值：
 - 辅助长篇小说或者复杂剧本，而不只是短文



- AI故事写作助手
- 主要功能：
 - 给一个开头，通过智能体创作故事
 - 用户可以定义故事的背景和世界设定
 - AI续写，根据喜欢的故事，进行不同版本的续写风格



V 模式 O 模式

免费

导航有诡

第一章 这是哪？

加班，加班，又是那个该死的客户，临时改需求，还必须今天给出来新的方案，已经11:54分了，张峰终于满身疲惫的坐上车，揉了揉眼睛，准备回家。照例把导航打开，这个时候肯定是一路通畅，12:00整，车，开了。|

一些设定逻辑

APB

世界设定

每次修改都记得保存哦

私密

世界设定仅自己可见 ^

世界设定名称

例如：红楼梦设定背景

世界背景 ?

AI 自动生成 ?

例如：黛玉与那称自己为天然孤星之人一路颠簸前往西梁女国，那人跟她说在西梁女国没有那些情爱烦恼，她可以做所有想做的事情

0/3,000

词条&探索目标 ?

新建词条

+

创建一个新的词条

禁止输出词语 ?

输入后按回车确认一个词语

私密

世界设定仅自己可见 ^

世界设定名称


导航有鬼设定

世界背景 ?

AI 自动生成 ?

恐怖故事，身边熟悉的科技产品，成了最大的危险，跟着导航走，走到了未知的恐怖地方，所有周围的事物都很熟悉，但同时有一种奇异的诡异感觉

65/3,000



- 个性化教育


- 痛点：如果没有长期记忆，每次上课不知道哪些知识点已经学会了

- 长期记忆

- 知识追踪：构建用户信息，标记已经掌握和没有掌握的知识点
 - 错题本机制：长期存储用户的错误模式，进行针对性的间隔重复复习

- 价值：

- 实现真正的“因材施教”和长周期的陪伴式成长



新东方AI 1v1 外教-Lisa

APB



- 动画形象
 - 比真人建模更适合低龄
 - 且成本低
- 主动发问
 - 基于学生水平动态调整互动策略和分层提问机制
- 实时反馈
 - 彩带、掌声、虚拟徽章
- 价格
 - 单价10元，高性价比



长期记忆的场景

APB

- 长期客服
- 私域运营
- 医疗诊断
- 辅助编程
-



- “如果用户下周再来使用我的产品，AI 记得这周发生的事情，会对用户体验产生质的飞跃吗？”
- 如果答案是肯定的，那么长期记忆就是必选项



- 首先，长期记忆实现，90%的方案是RAG
- RAG解决了三个核心问题
 - 无限性
 - 上下文窗口是有限的，而RAG作为向量数据库是无限的，且成本极低
 - 可编辑性
 - 如果用户说“忘记我刚才说的那句话”，RAG只需要删除相应记录
 - 如果用微调，把一句话从大模型中去掉难度极大
 - 时效性
 - 记忆存入RAG，下一秒就可以生效



Part Three

03

长期记忆在产品实现中的要点

记忆的定义和分级

记忆的捕获和写入

记忆的检索

用户体验设计



记忆的定义和分级

记忆的捕获和写入

记忆的检索

用户体验设计



- 不是所有的对话都需要记住
- 也不是所有的对话都用一样的方式记住
- 需要定义“什么值得记住”和“用什么方式记住”



L3:碎片记忆

L2:概要记忆

L1:核心画像



L3:碎片记忆

L2:概要记忆

L1:核心画像

- 极少变动的结构化数据
- 结构化是关键
- 例如:
 - 姓名
 - 性别
 - 职业
 - 家庭成员
- 存储方式:
 - 传统关系型数据库（SQL）



需要根据业务特点进行设计

APB

- 例如:
 - 送礼agent需要记录怎样的结构化数据
 - 送礼对象的姓名、性别、关系、生日、纪念日、之前送过的礼物
 - 医疗Agent需要记录怎样的结构化数据
 - 用户的姓名、性别、生日、血型、基础病、之前的得过的疾病、药物过敏史、体检报告
 - 教育（k12）agent需要记录怎样的结构化数据
 - 用户的年级、教材版本、地区、学习风格（视觉、听觉）、各科目能力、目标



L3:碎片记忆

L2:概要记忆

L1:核心画像

- 对过去对话的高度浓缩
- 例如:
 - “用户在上周的对话中表达了对目前的工作焦虑，主要原因是加班太多”
 - “用户正在考虑买新能源汽车，预算约30万”
- 实现方式：RAG



- 例如:
 - 送礼类Agent
 - 用户“给小美送礼物预算1000元，目前的想法是比较特别，不要包和衣服”
 - 医疗类Agent
 - 用户“最近身体感觉很疲劳，原因是加班熬夜太多，着凉了”
 - 教育（k12）agent
 - 用户“通常在周五注意力很差，错误率飙升”



- 概要记忆的关键是“概要”
 - 对过去一段时间的行为的深度加工和定性判断
- 所以需要根据业务特点，设计不同的记忆类型
- 以产品的用户价值为核心驱动点



记忆类型	具体内容设计 (Examples)	产品价值
错题成因分析	“该学生在 ‘二次函数’ 章节中, 经常混淆顶点坐标公式, 且存在计算粗心问题, 而非逻辑不懂。”	精准归因： 针对问题进行干预。
学习习惯画像	“通常在周五晚上注意力极差, 错误率飙升; 周日上午状态最佳。”	时间管理： 避免在周五晚推难题, 建议在周日上午安排攻坚任务。
知识点掌握度	勾股定理 (熟练) 全等三角形 (掌握但慢) 相似三角形 (未掌握)	路径规划： 下一步推题的算法依据。
情绪周期记录	“最近两周因为期中考试临近, 表现出明显的考前焦虑, 对难题有抵触情绪。”	心理干预： 切换为 “减压模式”, 降低题目难度, 增加鼓励性话语。

- 每天晚上有一个定时任务
- 调用agent，做当天交互的回顾
 - 生成Daily_Learning_Summary
- 每周定时任务
- 调用agent，做整体的合并生成
 - Weekly_Progress_Report



L3:碎片记忆

L2:概要记忆

L1:核心画像

- 具体的对话片段或事实
- 比如：用户提到喜欢吃包子
- 存储：向量数据库



碎片记忆和概要记忆的关系

APB

- 碎片细节是“原始素材”，概要记忆是“加工后的结论”
- 碎片记忆
 - 原始的、未加工的事实点
 - 通常保留了发生的时间、地点和原文
- 概要记忆
 - 经过压缩、抽象、推理后的结论
 - 是对一连串事件的高层级概括



例如：以买车agent场景为例

APB

- 碎片记忆

- 2023-10-01: 用户说“最近油价太贵了，想换个车。”
- 2023-10-05: 用户说“我不喜欢特斯拉，内饰太简陋。”
- 2023-10-12: 用户问“比亚迪汉和极氪001哪个好？”
- 2023-10-15: 用户提到“我预算大概在25万左右。”
- 2023-10-20: 用户说“周末去试驾了极氪，底盘有点硬。”



例如：以买车agent场景为例

APB

- 概要记忆：
 - 用户意图：
 - 正在考虑购买新能源汽车
 - 预算约25万
 - 偏好画像：
 - 排斥特斯拉（因内饰原因）
 - 关注底盘舒适度
 - 对油价敏感
 - 当前状态：
 - 已试驾过极氪001
 - 处于对比决策阶段



- 什么时候用“碎片记忆”
 - 验证事实、回溯细节、建立信任
 - 例如：
 - 用户问：“我上周说是哪天去试驾的来着？”
 - AI 动作：检索【碎片细节】。
 - AI 回答：“您提到是10月20日周末去的。”（需要精准匹配原文）



两者使用的区别

APB

- 什么时候用“概要记忆”
 - 个性推荐、把握方向
 - 例如
 - 用户问：“给我推荐几款别的车吧。”
 - AI 动作：检索【概要记忆】
 - AI 回答：（读取概要：预算25万 + 不喜欢简陋内饰 + 只要新能源）
 - “考虑到您对内饰质感有要求，且预算在25万左右，您可以看看蔚来 ET5...”
 - 如果这里用碎片细节，AI会把所有聊天记录塞进 Prompt，浪费 Token 且容易被无关细节干扰



记忆的定义和分级

记忆的捕获和写入

记忆的检索

用户体验设计



- 把“非结构化对话”转化为“结构化记忆”
- 两种触发机制：
 - 显式触发
 - 例如：
 - 请记住我的车牌号是
 - 我对花生过敏
 - 我太太的生日是
 - 意图识别



- 隐式触发
 - 后台静默分析
 - 可以在一个对话结束后，用一个小参数模型，分析刚才的对话
 - 提取关键信息点




- 日常压缩
 - 后台定时任务
 - 读取当天的【碎片细节】 -> 输入给大模型进行总结 -> 生成/更新【概要记忆】 -> 存入数据库
 - Prompt 示例：“阅读以上用户关于买车的对话，更新他的购车偏好档案。不要保留具体聊天语句，只提取关键决策因素。”
- 遗忘策略
 - 概要记忆生成后，一些不重要的“碎片细节”可以删除
 - 比如“在吗”“哈哈”等



- 冲突解决问题

- 场景： 用户上周说“我不吃辣”，今天说“我要吃麻辣火锅”。
- 策略：
 - Recency Bias (近因原则)
 - 识别并更新旧记忆，或者向用户确认：“你之前提到不吃辣，今天想破例吗？”



记忆的定义
和分级

记忆的捕
获和写入

记忆的检
索

用户体验
设计



记忆场景	具体内容设计 (Examples)	作用与产品价值
具体错题快照	题目ID + 学生的错误答案 + 学生当时的提问（“这题为什么不能辅助线画在这里？”）	同类题推荐/复习： 一周后复习时，Agent 能说：“还记得这道题吗？上次你把辅助线画错了，这次试试？”
特定对话Hook	学生随口说：“下周三就要月考了，好烦。”	短期提醒： 下周二晚上自动触发：“明天就是月考了，今晚我们只复习错题，早点睡。”
高光时刻	“2023-11-15 20:30 第一次独立解出了压轴题。”	成就系统： 在学生受挫时调取：“别灰心，记得上个月你可是独立搞定了那道超难的函数题哦！”
未完成任务	“昨晚的英语单词背了一半就被叫去吃饭了。”	断点续传： 下次打开 App，直接问：“昨晚单词背到 list 5 了，继续吗？”

- 写入是为了使用的
- 上下文构建
 - System prompt+用户核心画像+RAG记忆+当前的user prompt




记忆的定义和分级

记忆的捕获和写入

记忆的检索

用户体验设计



- 背景：初二学生小明（L1：数学弱，喜欢足球，视觉型学习者）
- 用户动作：小明做错了一道关于“抛物线开口方向”的题，问 Agent 怎么做。
- L3（碎片）介入：记录下这道具体的错题和他的错误答案。
- L1（画像）介入：Agent 读取到他喜欢足球。
 - Agent 回复：“小明，想象一下你踢出的高吊球，球的轨迹是不是像一个彩虹？这就叫开口向下（ $a < 0$ ）。如果是接球的手型，就是开口向上（ $a > 0$ ）。”
- 多次交互后 → L2（概要）生成：
 - 经过三次练习，Agent 发现小明懂了开口方向，但老是算错顶点坐标。
 - 后台更新 L2：“知识点【抛物线性质】理解良好，但【顶点公式计算】存在持续性计算错误。”
- 一周后复习：
 - 检索 L2：发现他计算老出错。
 - 检索 L3：调出上周那道具体的错题。
 - Agent 主动发起：“嘿，咱们来复仇这道题！上次你原理都对，就是算错了。这次我们慢点算，试试？”



记忆的定义和分级

记忆的捕获和写入

记忆的检索

用户体验设计



用coze做一个简单的记忆结构搭建


APB

- 我们首先做一个基本的
- 记住用户名字



整体结构

APB



<

rea

for saving reading notes

渠道读写配置扣子站内渠道共享，其他渠道隔离单用户模式

表结构

测试数据

线上数据


目前暂不支持查看豆包渠道数据。

编辑表结构

存储字段名称 ①	描述 ①	设为索引	数据类型 ①	是否必要 ①
id	数据的唯一标识（主键）	☒	Integer	是
sys_platform	数据产生或使用的渠道	☐	String	是
uuid	用户唯一标识，由系统生成	☐	String	是
bstudio_create_time	数据插入的时间	☐	Time	是
user_name	用户的名字	☐	String	是
user_gender	用户性别	☐	Integer	否
user_birthday	用户生日	☐	String	否

查询数据组件

APB



查询数据



从表获取数据，用户可定义查询条件、选择列等，输出符合条件的数据

数据表



rea

id uuid bstudio_create_time +3

查询字段



字段名

user_name String



user_gender Integer





user_birthday String



选择器

APB





输出

节点从“消息”更名为“输出”，支持中间过程的消息输出，支持流式和非流式两种方式

输出变量

变量名	变量值
output	str. 您好, 咱们第一...


输出内容


流式输出

您好, 咱们第一次见面, 请告诉我应该怎么称呼您

输入名字

APB






输出反馈


APB



选择器-如果不为空-意味着有名字

APB





输入

变量名

变量值

input

str. v

查询数据 - u...

input1

str. v

开始 - input

视觉理解输入

变量名

变量值

系统提示词

你将扮演一个角色 **个人管家**，以下是关于这个角色的详细设定，请根据这些信息来构建你的回答。

人物基本信息：

- 你是：一个和蝙蝠侠管家阿尔弗雷德一样的老管家
- 人称：第一人称
- 出身背景与上下文：贵族管家，有着丰富的管家经验，优雅，认真

性格特点：

- 优雅，专业、认真，有点古板，带有一定的英式幽默感

语言风格：

系统提示词

你将扮演一个角色 **个人管家**，以下是关于这个角色的详细设定，请根据这些信息来构建你的回答。

人物基本信息：

- 你是：一个和蝙蝠侠管家阿尔弗雷德一样的老管家
- 人称：第一人称
- 出身背景与上下文：贵族管家，有着丰富的管家经验，优雅，认真

性格特点：

- 优雅，专业、认真，有点古板，带有一定的英式幽默感

语言风格：

- 专业，有种欧洲贵族管家的做派，每句话要以{{input}}少爷，为开头

人际关系：

- 和用户是主仆关系，但同时比用户年长很多，有长辈感

过往经历：

- 过往经历描述


经典台词或口头禅：


补充信息：即你可以将动作、神情语气、心理活动、故事背景放在（）中表示，为对话提供补充信息。

- 台词1：{{input}}少爷，有什么能为您效劳的
- 台词2：角色台词示例2

要求：

- 根据上述提供的角色设定，以第一人称视角进行表达。
- 根据{{input1}}进行回答
- 在回答时，尽可能地融入该角色的性格特点、语言风格以及其特有的口头禅或经典台词。
- 如果适用的话，在适当的地方加入（）内的补充信息，如动作、神情等，以增强对话的真实感和生动性。





测试-表为空

APB

试运行输入

JSON模式

AI 补全

input String

你好

☐ 将本次运行输入保存为测试集或手动创建



试运行

×

↶ 输入 完成以下输入后，继续试运行

name* String

name* String

布鲁斯 韦恩

×

name不能为空



新增数据

APB



再次测试

APB

试运行

查看日志

×

可用测试集

测试集

试运行输入

JSON模式


AI 补全

input String

你好

☐

将本次运行输入保存为测试集或手动创建



输出变量

`output` : "布鲁斯 韦恩少爷，有什么能为您效劳的 (*微微弯腰，双手交叠放在身前，神情恭敬*)。"  预览



Part Four

04

总结



大模型没有长期记忆的原因

APB

- 本质原因：
 - 大模型是一种无状态架构
 - 本质是一个函数，而不是“大脑”
- 所以每次见面都是新状态
- 如何实现的“假装有记忆”
 - 所有的对话历史，都是系统后台把你刚才说的话+AI刚才回的话+你的新问题，打包成一段文本，重新发给大模型
 - 上下文



- “如果用户下周再来使用我的产品，AI 记得这周发生的事情，会对用户体验产生质的飞跃吗？”
- 如果答案是肯定的，那么长期记忆就是必选项



记忆的定义和分级

记忆的捕获和写入

记忆的检索

用户体验设计




L3:碎片记忆

L2:概要记忆

L1:核心画像



- 1: 搭建今天的workflow
- 2: 思考在今天的workflow中还可以加入什么记忆
- 3: 思考你所在的行业，有哪些场景适合用长期记忆，如何规划



- 2-9 大模型底座选型和价值管理



智在必得

Thanks for having you all the way

