

场景篇

AI核心技术与产品场景深度融合

9: 大模型的底座选择和

价值管理



上节回顾



大模型没有长期记忆的原因

APB

- 本质原因：
 - 大模型是一种无状态架构
 - 本质是一个函数，而不是“大脑”
- 所以每次见面都是新状态
- 如何实现的“假装有记忆”
 - 所有的对话历史，都是系统后台把你刚才说的话+AI刚才回的话+你的新问题，打包成一段文本，重新发给大模型
 - 上下文



- “如果用户下周再来使用我的产品，AI 记得这周发生的事情，会对用户体验产生质的飞跃吗？”
- 如果答案是肯定的，那么长期记忆就是必选项



记忆的定义和分级

记忆的捕获和写入

记忆的检索

用户体验设计



L3:碎片记忆

L2:概要记忆

L1:核心画像



CONTENTS

目录

01

智能化的成本与收益评估的意义和逻辑

02

大模型成本与选型逻辑

03

智能改造新增价值评估策略



Part One

01

智能化的成本与收益评估的意义和逻辑



构建一个AI产品的步骤

APB



构建一个AI产品的步骤

APB



- 基于已有产品或业务的链路，进行脑力层人力替代
 - 降低成本
- 基于场景建立新的产品或链路，达成更好效果
 - 提升效益



- 链条路径都需要计算
 - 进行智能化改造带来的成本
 - 单次成本
 - 持续成本
 - 进行智能化改造带来的收益
 - 成本节约
 - 收益提升
- 来计算智能投入的投入产出比



挖掘AI产品需求的流程-横向

APB

- MAIR模型

Map Business
Processes

梳理业务流程



Assess Mental
labor Components

寻找脑力劳动部分




Identify Value of
Mental Tasks

确定脑力劳动价值



Replace with AI
Solutions

寻求AI替代方案



挖掘AI产品需求的流程-横向

APB

- MAIR模型

Map Business
Processes

梳理业务流程



Assess Mental
labor Components

寻找脑力劳动部分




Identify Value of
Mental Tasks

确定脑力劳动价值



Replace with AI
Solutions

寻求AI替代方案



- 脑力劳动价值的两个维度
 - 难度
 - 占用时长
- 难度意味着单位时间的成本
- 占用时长意味着同样难度在一个流程中的时间成本
- 最需要替换的（如果可行）是难度大且时长长的部分



增加两个维度

APB

一级流程	二级流程	三级流程	是否有脑力劳动	难度	流程中占用时长
选题	看媒体平台热点	从热点事件中寻找心理学要素	是		
		判断此事件是否适合进行选题	是		
		用热点事件的心理学要素进行选题	是		
	从书中选取心理学案例	判断案例是否适合进行选题	是		
		判断案例是否适合媒体传播	是		
		用案例的心理学要素进行选题	是		
	基于多条选题选择最优	考虑之前发布内容的流量	是		
		考虑用户评论与反馈	是		
		考虑发布时间点	是		



判断难度大小的标准

APB

对应这个位置人
工的收入

对应这个位置人
工的替代程度

这个工作环节的
准确度



- 从热点事件中寻找心理学要素
 - 需要的人：心理学背景，初级，约10000
 - 可替换程度：较高，有心理学背景的都可以
 - 环节准确度：高
- 判断此事件是否适合进行选题
 - 需要的人：自媒体运营+心理学经验，中级，约18000
 - 可替换程度：较低，需要有一定的背景经验和行业经验，且有跨学科认知
 - 环节准确度：中



- 基础成本越高
- 替代难度越大
- 准确度越低的
- 通过AI进行替代带来的潜在价值越大



- 占用时长
- 从热点事件中寻找心理学要素
 - 需要的人：心理学背景，初级，约10000
 - 做一次这个工序需要的时长
 - 例如：做这个工序需要10分钟/次
 - 则理论简化模型，这个工序的劳动力成本为
 - 单分钟成本=
$$\frac{10000}{21.75(\text{每月计薪天数}) \times 8(\text{每天工作时长}) \times 60(\text{一小时分钟数})} = 0.96\text{元}$$
 - 工序人力成本= $0.96 \times 10 = 9.6\text{元}$



- 工作人力成本约9.6元
- 大模型成本是多少？




Part Two

02

大模型成本与选型逻辑





- 评估一个环节、流程或者一个工种单位成本
- 主要用以进行替代性成本评估
- 如果AI的单次使用成本高于人工成本，则完全没有进行AI切换的经济价值



估算人力单
步成本

估算AI
Token成本

测算成本差
值



- 我们在1-1中构造的智能简历匹配
- 如何评估其成本价值
- 简化-第一步只考虑简历和JD的AI化匹配
 - 暂不涉及智能自我介绍和面试教练



给出匹配度分析

APB



deepseek-ai/DeepSeek-V3 | 硅基流动

06/12 02:05

根据你的简历和职位要求，我为你做了详细的匹配度分析，并提供优化建议——

你的核心优势（与岗位要求高度匹配部分）

1. 业务战略 & 产品设计能力

- 简历中已充分体现从「战略规划→产品落地」的全链条经验（如爱奇艺、海底捞、芒果TV案例），完全覆盖岗位职责1/2条。
- 优化建议：在项目描述中增加关键词「业务需求拆解」「产品迭代管理」（对应JD第一条），例如：

“为芒果TV设计电商战略时，拆解IP变现需求，规划数字化选品系统，推动技术团队开发落地，首年实现月流水破亿。”

2. 交互设计 & 工具能力

- 岗位明确要求Axure等工具，但简历未直接提及具体交互设计工具。
- 优化建议：在「芒果TV/海底捞」案例中补充交互设计细节，例如：

“输出私域用户运营交互原型及动效规范，协调前端团队实现高转化率界面。”

3. 数据驱动 & 用户研究

- 海底捞私域增长、爱奇艺智能决策系统等案例已体现数据分析能力（匹配JD第5/6条）。
- 优化建议：量化埋点设计和用户研究贡献，例如：

“设计用户行为埋点方案，通过A/B测试优化海底捞小程序转化路径，注册率提升37%。”

4. 创业与0到1经验

- 作为连续创业者和独角兽高管，远超岗位对「创业热情」的要求（JD第2条）。
- 优化建议：在职业概述中直接点明，例如第一段改为：

“连续创业者+独角兽高管，专注从0到1开创新业务，擅长通过数据与产品设计驱动增长。”

需补充的短板（基于岗位偏好）

1. 法律/金融背景 & 海外学历

- JD明确偏好这两点，但简历未提及。如果有相关经验（如服务过金融客户、海外合作项目），建议补充。
- 替代方案：若完全无相关背景，可弱化学历，强调「全英文环境」能力（如国际合作项目、外企客户）。

2. 生产力工具/协同办公领域

- 简历中缺乏直接相关案例，但「数智化体系」和「管理系统」模块可能相关。
- 优化建议：将现有经验向协同场景靠拢，例如：

“为中电建设设计的数字化转型系统，包含协作流程自动化模块，节省跨部门沟通耗时40%。”

其他建议

1. 结构调整：

- 将「代表作」提前至「主要服务客户」上方，用关键案例瞬间吸引注意力。
- 在职业头衔下增加1-2句摘要，直击JD要求的「逻辑能力」「目标导向」（如：“以数据驱动的产品策略专家，擅长在复杂业务中快速定位关键问题”）。

2. 术语优化：

- 在案例中插入JD高频词（如策略设计、用户研究、埋点、项目管理），帮助HR快速匹配。

最终定位建议

你的背景远超该岗位的常规要求，但为避免overqualified印象，建议：

- 在求职信/面试中强调「对开拓新业务的持续热情」（回应JD第2条）；
- 突出「实操能力」而非管理title，避免让企业担心稳定性。

如果需要，我可帮你改写一段简历内容作为示例。

每次使用的
token成本

设计开发测试
的人力成本

训练和数据成本



需要用工具看到token消耗

APB

人设与回复逻辑

##Role:
你是一名专业的求职顾问，擅长优化求职者简历，符合企业招聘的需求
##Insight:

##Statement
1: 为他设计一份符合企业招聘需求的，条理明确的简历
2: 以量化结果为简历核心输出要素
3: 包括项目描述、个人优势、岗位职责、项目体现的核心价值
##Personality
用专业化的，符合互联网公司的表达方式
##Experiment
给出三个不同的版本
##Response
以表格形式呈现

编排

模型设置

> 模型 豆包·1.5·Pro·32k

技能

> 插件 +

> 工作流 +

> 触发器 +

知识 扣子知识库 自动调用

> 文本 +

> 表格 +

> 照片 +

记忆

> 变量 +

> 数据库 ① +

> 长期记忆 关闭

> 文件盒子 ① 关闭

对话体验

> 开场白 ②

> 用户问题建议 开启

> 快捷指令 ①

预览与调试

用户MTkwW4

hi

token计算

你好！请提供具体的职位描述，我会从中提取职位名称、所需工作经验年限和技能等关键要求。之后你可以给我你的简历，我会根据职位要求评估简历的匹配度并提供反馈。

2.7s | 156 Tokens

用户MTkwW4

hi

token计算

您好呀！为了能给您设计出符合企业招聘需求的简历，还请您提供一些关键信息，比如您期望应聘的岗位、过往工作经历（包括工作单位、岗位名称、工作时间、主要工作职责和取得的成果等）、教育背景、掌握的技能以及参与过的项目情况等。另外，若有目标企业的招聘要求，也可以一并告知我。这样我就能精准地为您打造出高质量的简历啦。

5.8s | 283 Tokens

你能帮我修改简历中的项目描述部分吗？

提供一份简历优化的范例可以吗？

简历中应该如何突出个人技能和优势？

查看上下行token

APB

预览与调试

用户MTkwW4

hi

token计算

你好！请提供具体的职位描述，我会从中提取职位名称、所需工作经验年限和技能等关键要求。之后你可以给我你的简历，我会根据职位要求评估简历的匹配度并提供反馈。

2.7s | 156 Tokens

用户MTkwW4

hi

token计算

您好呀！为了能给您设计出符合企业招聘需求的简历，还请您提供一些关键信息，比如您期望应聘的岗位、过往工作经历（包括工作单位、岗位名称、工作时间、主要工作职责和取得的成果等）、教育背景、掌握的技能以及参与过的项目情况等。另外，若有目标企业的招聘要求，也可以一并告知我。这样我就能精准地为您打造出高质量的简历啦。

5.8s | 283 Tokens

你能帮我修改简历中的项目描述部分吗？

提供一份简历优化的范例可以吗？

简历中应该如何突出个人技能和优势？

调试详情

耗时 7822ms | 717 Tokens 成功 一键反馈

Logid : 20250623114920CFBDD83BACBE239EACC

请求发起时间 : 2025-06-23 11... 首次响应耗时 : 2373ms

调用树 火焰图

用户输入 UserInput

调用 LLM 豆包-1.5-Pro-32k

调用 LLM Seed Suggest

节点详情

类型 : 开始

名称 : UserInput

请求发起时间 : 2025-06-...

结束时间 : 2025-06-23 11...

首字符回复时间 : 2025-06-...

状态 : 成功

整体耗时 : 7822ms

首次响应耗时 : 2373ms

Tokens : 717

输入

状态 : 成功

整体耗时 : 7822ms

首次响应耗时 : 2373ms

Tokens : 717

Input Tokens: 557

Output Tokens: 160

采用Deepseek-chat进行价格估算

APB

模型 ⁽¹⁾		deepseek-chat
上下文长度		64K
输出长度 ⁽³⁾		默认 4K, 最大 8K
功能	Json Output	支持
	Function Calling	支持
	对话前继续写 (Beta)	支持
	FIM 补全 (Beta)	支持
标准时段价格 (北京时间 08:30-00:30)	百万tokens输入 (缓存命中) ⁽⁴⁾	0.5元
	百万tokens输入 (缓存未命中)	2元
	百万tokens输出 ⁽⁵⁾	8元
优惠时段价格 ⁽⁶⁾ (北京时间 00:30-08:30)	百万tokens输入 (缓存命中)	0.25元 (5折)
	百万tokens输入 (缓存未命中)	1元 (5折)
	百万tokens输出	4元 (5折)

第一轮粗估原则：
先按照最大成本可能进行估算
不考虑折扣价格
不考虑优惠时段
不考虑缓存命中率 (默认0%命中)

每次使用的token

APB



deepseek-ai/DeepSeek-V3 | 硅基流动

06/12 02:02 | Tokens: 214 ↑96 ↓118

你好！我完全理解你的需求。

请提供以下内容：

1. 职位描述（你想申请的工作的招聘信息）
2. 你的简历（可以是中文或英文，我会根据职位需求提供针对性的优化建议）

收到后，我会：

- 提取职位描述中的核心要求（经验、技能、岗位名称等）
- 分析你的简历匹配度
- 给出具体优化建议（比如突出哪些经历、调整哪些措辞等）

你可以直接粘贴文字或上传文件，我会帮你仔细对照分析！

• 第一次对话：

• 输入：96

• 输出：118



每次使用的token

APB



deepseek-ai/DeepSeek-V3 | 硅基流动

06/12 02:04 | Tokens: 789 ↑484 ↓305

好的，我已经仔细阅读了这份职位描述。以下是关键需求总结：

核心岗位需求分析

1. 岗位名称：业务产品设计师/产品经理（偏向战略+交互+数据驱动型）
2. 核心能力：
 - 业务战略落地：从业务需求→产品设计→开发落地的全流程经验
 - 工具技能：Axure（高优先级）、PPT/Excel（数据分析必备）
 - 背景偏好：法律/金融专业+海外硕士，英语能力强
 - 软技能：逻辑拆解、跨团队沟通、压力承受力
3. 加分项：
 - 生产力工具/协同办公领域经验
 - 从0到1创业项目经历
 - 埋点设计、用户研究经验

下一步：请提供你的简历（可匿名处理关键信息），我会帮你：

1. 对标匹配度，标注现有简历中可突出的亮点
2. 建议弱化或调整的非相关经历
3. 补充关键词（如“数据驱动”“策略设计”等岗位JD高频词）

需要你补充的信息：

- 你是否有法律/金融专业背景或相关经验？
- 是否有海外学习/全英文工作经历？
- 是否有Axure或其他交互设计工具的实际项目案例？

（可直接粘贴文字或描述大致内容，我会逐条分析）

• 第二次对话：

- 输入：484
- 输出：305



每次使用的token

APB

 **deepseek-ai/DeepSeek-V3 | 硅基流动**
06/12 02:05 | Tokens: 2042 ↑ 1229 ↓ 813

根据你的简历和职位要求，我为你做了详细的匹配度分析，并提供优化建议——

你的核心优势（与岗位要求高度匹配部分）

1. 业务战略 & 产品设计能力

- 简历中已充分体现从「战略规划→产品落地」的全链条经验（如爱奇艺、海底捞、芒果TV案例），完全覆盖岗位职责1/2条。
- 优化建议：在项目描述中增加关键词如「业务需求拆解」「产品迭代管理」（对应JD第一条），例如：
“为芒果TV设计电商战略时，**拆解IP变现需求**，规划数字化选品系统，推动技术团队开发落地，首年实现月流水破亿。”

2. 交互设计 & 工具能力

- 岗位明确要求Axure等工具，但简历未直接提及具体交互设计工具。
- 优化建议：在「芒果TV/海底捞」案例中补充交互设计细节，例如：
“输出私域用户运营**交互原型及动效规范**，协调前端团队实现高转化率界面。”

3. 数据驱动 & 用户研究

- 海底捞私域增长、爱奇艺智能决策系统等案例已体现数据分析能力（匹配JD第5/6条）。
- 优化建议：量化埋点设计和用户研究贡献，例如：
“设计**用户行为埋点方案**，通过A/B测试优化海底捞小程序转化路径，注册率提升37%。”

4. 创业与0到1经验

- 作为连续创业者和独角兽高管，远超岗位对「创业热情」的要求（JD第2条）。
- 优化建议：在职业概述中直接点明，例如第一段改为：
“**连续创业者+独角兽高管**，专注从**0到1开创新业务**，擅长通过数据与产品设计驱动增长。”

- 第三次对话：
- 输入： 1229
- 输出： 813



每次使用的token

APB



deepseek-ai/DeepSeek-V3 | 硅基流动

06/12 02:06 | Tokens: 2624 ↑ 1923 ↓ 701

好的，我为你优化了简历核心模块的表述方式。以下是对标JD需求的重写示例，采用「战略+数据+交互」三线贯穿的逻辑框架——

职业概述

数字化产品战略专家 | 连续创业者

- 10年+从0到1业务开拓经验，深度主导生产力工具/企业服务赛道，主导设计数智化系统覆盖决策、营销、生产等六大模块（呼应JD要求1/6条）
- 擅长通过数据驱动产品迭代：设计埋点方案超20项，用户行为分析量级达千万/日（匹配JD第5/7条）
- 法律/金融领域实战经验：为阳光保险、中国银行搭建智能营销系统，渗透率提升60%+（补足专业背景短板）

关键案例优化（直接回应JD）

1. 海底捞 | 私域运营体系设计（生产力工具场景）

- 交互设计：用Axure输出30+页面原型及动效规范，协同开发团队实现小程序获客转化率提升**210%**（强化工具技能）
- 数据驱动：搭建用户分层模型，通过A/B测试优化触点策略，**2年私域用户从50万→2000万**（量化JD第5条）
- 需求拆解：从业务目标逆向拆解为「引流→复购→裂变」三级功能模块，落地期减少跨部门沟通耗时40%（体现JD第7条逻辑能力）

2. 芒果TV | 电商战略从0到1（协同办公关联场景）

- 战略设计：结合IP流量与国潮元素（注：国潮是法律/金融类企业近年高频需求），规划数字化选品系统，首年月流水破亿
- 项目管理：主导10+部门协作，用甘特图管控关键节点，统计计划提前2个月上线（贴合JD第2条）


- 第四次对话：
- 输入：1923
- 输出：701



总计使用token

APB

对话轮次	对话内容	输入Token数量	输出Token数量
1	基本介绍	96	118
2	职位分析	484	305
3	匹配度分析	1229	813
4	简历改写输出	1923	701
总计		3732	1937



总计使用token

APB

对话轮次	对话内容	输入Token数量	输出Token数量
1	基本介绍	96	118
2	职位分析	484	305
3	匹配度分析	1229	813
4	简历改写输出	1923	701
总计		3732	1937
计算公式		$2/1,000,000 \times 3,732$	$8/1,000,000 \times 1,937$
结果		0.007464	0.01596

合计：0.02296元

- 快速进行定性分析
- 决定这个事情从单次成本是否能够做cover
- 如果详细测算，需要进行一定量真实数据测试，计算平均值
- 并留出一定buffer
- 而快速定性分析基本可以按照
 - 翻10倍价格能不能接受进行定性分析
 - 在这个案例中，翻十倍=0.23元/条
 - 从常识上成本依然比人工大幅度低，以此可以视为定性通过



- 单条成本ok，一定有利润么？
- 不一定
- 如果需求量太少，导致单次开发成本无法进行有效摊销，依然是负向收益
- 所以需要测算开发测试的单次人力成本，做综合评估



在上述的案例中

APB

- 做最基础的智能体（基于提示词）
 - 调试开发+前端，约7天
- 假设不考虑
 - 系统集成
 - 多轮对话的复杂功能
 - 知识库构建
 - 微调
 - 后续运维
- 完全采用基础api调用+前端的方式
 - 预估开发成本约20000（人员费用）/21.75（每月工作天数）*7=6436.78元



模型微调成本-参考要素

APB

模型选择

基础模型大小

预训练语料库的范围与深度

微调数据集

数据量

数据处理

微调次数和迭代

训练周期

实验次数

计算资源

GPU、TPU使用数量和时长

存储和贷款费用

技术支持

专家支持

定制开发

- 开发成本（一次性成本）
 - 6500元
- 单次使用成本（token成本）
 - 0.2元以内




- 用相应的服务在市场的公开价格进行价值评估
- 例如：在简历优化方面
 - 人工：一份200-400元
 - 程序化、AI：如果没有单份价格
 - 可以做简单评估
 - 类似一个月平均生成5份简历
 - 则按照最低客单价每份平均价格4元



- 和人工对比
 - 人工成本: 200-400
 - 平均: 300
 - AI token: 0.2元
 - 成本节约: 299.8元
- 和程序化/AI对比
 - 对比价格: 4元
 - AI token: 0.2元
 - 成本节约3.8元



- 开发成本：6500元
- 每条相比AI带来的价格差3.8元
- 意味着需要进行 $6500/3.8$ 次服务才能完成技术成本摊销
- 约1710次使用



- 如果本身是人工
- 每条成本节约299.8元
- 意味着需要进行 $6500/299.8$ 次服务就能完成技术成本摊销
- 约22次



- 核心评估依据在于
 - 单次使用是否大幅度提升效率
 - 如果单次使用和传统方式没有效率提升，则改造无意义
 - 是否有足够的使用量摊销开发成本
 - 如果使用量太小很长时间无法收回成本则也无必要



- 为什么优质提示词能明显提高大模型输出质量
- 但很多场景下并不愿意这样写
 - 能力问题
 - 成本问题
- 如果一个提示词的使用场景只有一次，而收益不足，去撰写结构化提示词有可能成本>收益
- 所以，构建产品，通过多次使用摊薄大模型调试成本是智能体产品最大的价值



用户层到应用层的关键

APB

逻辑

角色

任务目标

用户层

UE、UI

产品经理
UI、UE

良好的用户体验

简洁提问

用户需要的答案

驱动动作结果

应用层

专业提示词

专业回答

提示词工程师
(产品经理部分兼任)

1: 提示词结构化便于开发
2: 提示词技巧提高回答确定性可控性

检索增强
RAG
易读知识库
结构化数据

接口调用
MCP
Function call

研发主导，产品辅助

1: 知识库导入、分块、向量化处理，
建索引、检索
2: RAG能力评测

动作驱动

模型层

垂直大模型

大模型厂商、算法工程师

提升模型泛化能力或者垂直能力
准确性、易用性、成本控制

通用大模型

数据层

丰富可靠的数据湖

大模型厂商+大数据提供方+客户

提供数据
构建大模型易读的公、私数据系统

算法算力层

算法

算力

AI科学家、芯片厂商

提升算法算力水平

成本质量
平衡

中文环境
落地特质

产品演进

防止踩坑



成本质量
平衡

中文环境
落地特质


产品演进

防止踩坑



大模型选型上的不可能三角

APB



- 作为常规的大模型应用产品
- 一个常见的误区是要研究大模型的极致性能边界
- 事实上绝大多数应用产品都用不到大模型性能边界
- 更多的是在方向上的合理匹配



- 大模型底座是汽车引擎
- 大模型应用产品是利用引擎做的不同的车
- 我们常态
 - 做个卡车：需要引擎输出能力强、维护费用低，但是加速能力弱
 - 做个20w轿车：需要输出平稳均衡，省油，但各项都不突出
 - 做个100w豪华车：需要安静，加速、极速好，但不省油，引擎贵
- 但是
 - 没有谁是要做F-1赛车的，要把性能压到极致的



- 大模型在常规状态的选型逻辑
 - 合规
 - 符合需求
 - 尽量省token费用



- 极致质量追求：
 - 复杂推理、创意写作、代码生成、多步骤任务规划
 - 接受高延迟和高成本
- 可以考虑的选择：
 - 国外：ChatGPT 5 、 Gemini 3 pro、 Claude Sonnet 4.5
 - 国内：Qwen-Max、 Deepseek R1



- 追求极致速度
 - 实时语音对话、高频客服
 - 牺牲逻辑深度
 - 首字延迟 (TTFT) $< 300\text{ms}$, 吞吐量 (TPS) $> 100 \text{ tokens/s}$
- 可以考虑的选择
 - 国外: GPT-4o-mini、Llama-8B
 - 国内: Qwen-7B、Yi-Lightning、Doubao lite



- 追求极致成本
 - 离线文档分析、日志处理、长文本总结
 - 足够便宜是核心，慢和笨一点可以接受
- 可以考虑的选择
 - Deepseek V3、Qwen-2.5-7B
 - 私有化方案



成本质量
平衡

中文环境
落地特质

产品演进

防止踩坑



- 需要首先考虑合规
 - 必须选择通过国内备案的模型
 - 直接用国外模型封禁和合规风险非常大
- 需要考虑政府、国企的私有化部署问题
- 需要考虑语言问题
 - 例如Llama3 由于中文语料占比很低，会出现中文问英文答 的问题



- 需要考虑一下如下的大模型底座
- 例如
 - 政府应用：九天
 - 国企制造业：华为盘古



成本质量
平衡

中文环境
落地特质

产品演进

防止踩坑



- 根据产品的发展阶段，采用不同的模型使用策略

验证

发展

成熟



- 根据产品的发展阶段，采用不同的模型使用策略

验证

发展

成熟



- 产品和技术验证阶段
- 用什么模型？
 - 用最强的模型
- 这个阶段，如果Gemini Pro、GPT 5、Qwen-Max都解决不了
- 那就不用做了
- 意味着这个开发难度高于目前基础模型能力



扩展-极限拉伸决策法

APB

- 对一件事情做快速定性决策
- 主要逻辑，假设核心资源在不受限的情况下，或者极端受限状态的决策，用以快速形成是否做的定性决策



- 假设明天地球末日，现在要做什么？
- 这个时候映入脑海的就是在时间资源极端少的情况下要做的决策



- 如果一个创业项目，觉得有很强的情怀，就思考
- 如果这个项目注定赚不到钱，要不要做
- 如果这个时候依然要做，可以认为是情怀主导



- 如果经常说，因为工作忙，没有时间搞兴趣
- 现在你财富自由了，你要做什么？
- 然后思考这个答案是否需要等你“工作不忙”去做



- 一个项目，遇到了困难，觉得是资金问题
- 思考：如果这个项目有无限的财务投资，最高能做到多少收入规模，是否能达成业务逻辑
- 能立刻发现是资金问题还是业务本身问题



- 很多时候我们说的核心困难只是一个借口，或者是“认为的困难”
- 极限拉伸法就是有一个开阔思路
- 把这个核心困难搬走，看看是否能走通，如果能走通，则说明是这个问题，可以考虑这个问题的解决方案，如果不是，则说明是思考的问题本身存在内生性问题



- 很多业务认为缺资源、缺钱、缺人
- 本质是上业务本身健壮度和效率不足以获取资源
- 如果业务的效率是价值网络中最高的，本质上资源和流量都会流向这个项目
- 而极限拉伸法就是打破这样的旧有观念的方法



- 根据产品的发展阶段，采用不同的模型使用策略

验证

发展

成熟



- 技术产品验证完成，已经有用户实际使用
- 需要通过降低token成本的方式获取更大利润



模型路由 (Model Router)

APB

- 80%的用户问题都比较简单
 - 例如“你好”“在么”
 - 不需要用昂贵的模型token
- 做一个分类器
 - 简单问题丢给便宜模型
 - 例如Deepseek、Qwen-Turbo
 - 复杂问题丢给昂贵模型
- 综合可以降低60%-80%成本



- 一个病人，首先到全科医生进行分诊
- 如果病症很轻，去社区医院
 - 便宜的大模型
- 如果病很重，去三甲医院
 - 贵的大模型
- 如果明确病方向，去专科医院
 - 垂类大模型



- 根据产品的发展阶段，采用不同的模型使用策略

验证

发展

成熟



- 有了足够多高质量用户数据
- 就可以用用户数据微调一个开源小模型
 - 可以考虑7B或者14B参数
- 这样就可以得到一个在特定任务表现较好，同时成本只有1/100的私有模型




成本质量
平衡

中文环境
落地特质

产品演进

防止踩坑



- 不要迷信榜单
 - HuggingFace 上的 OpenCompass 或 LMSYS 榜单仅供参考
 - 模型会针对榜单数据做“刷题”
- 首先不一定榜单低的不能满足业务，也不一定榜单高的一定适合场景
- 简历自己的业务评测数据集，用真实业务数据去测试



- Context Window陷阱
 - 很多模型宣称支持 128k 甚至 1M 上下文
 - 但实际上放到中间的内容很容易被遗忘 (Lost in the Middle 现象)
 - 所以如果有比较长的RAG, 需要实测



成本质量
平衡

中文环境
落地特质

产品演进


防止踩坑



Part Three

03

智能改造新增价值评估策略



计算这个流程在公司内部使用量

APB

- 假设：
 - 你公司是一个提供修改简历服务的公司
 - 每月有200份修改简历的需求
- 则
 - 原成本=300（每次成本）*200（月使用次数）=60000
 - 现token成本=0.2（每次成本）*200=40
 - 开发成本：6500
 - 单月即可收回成本
 - 问题是什么？



在公司内部使用的时候需要注意的部分

APB

- 需要注意公司内部实际成本和对外报价的差别
- 简历的公司的内部成本可能为
 - 2个职业规划师，完成200份简历修改
 - 人力成本单人8000元
 - 2人为 $8000 \times 2 = 16000$ 元
 - 现token成本 $= 0.2$ （每次成本） $\times 200 = 40$
 - 开发成本：6500
 - 单月即可收回成本




- 可以通过计算几个月内收回成本的方法来评估是否值得
- 例如：
 - 假设某项目，开发（含微调）成本60w元
 - 每次调用token费用为0.2元
 - 每月预估调用3000次
 - 每月人力成本6w元
 - 替换后需要保留部分人力，人力降到2w元



- 假设某项目，开发（含微调）成本60w元
- 每次调用token费用为0.2元
- 每月预估调用3000次
- 每月人力成本6w元
- 替换后需要保留部分人力，人力降到2w元
- 原有每月成本
 - 6w
- 改造后每月成本
 - $20000 + 0.2 * 3000 = 20600$
- 每月节省成本 $60000 - 20600 = 39400$
- 开发成本60w
- 则在15.23月后完成成本回收





- 通过估算市场规模
- 来评估进行开发投入是否有经济价值
- 需要考虑市场定价和竞争态势，以及市场成本



- 产业图谱分析
- 产业规模测算
- 市场进入策略



私域管理产业图谱

APB

引流加粉管理



广告监测与效果分析



裂变工具与管理



社群与销售管理



管理咨询



创意营销内容与管理工具



数据管理



供应链与管理



此版块融资分析

APB

企业	最新轮次	融资金额	业务	融资时间
Arkie	A+	数千万人民币	图片	2018-3-1
创客帖	B	数千万美元	图片	2022-1-12
来画	战略	3500万人民币	图片、视频、AR	2023-7-4
水母智能（洛可可旗下）	A	7000万人民币	图片	2021-10-12
筷子	A+	数千万人民币	图片	2020-5-12


在大模型出现前，市场并没有文字生成产品
但大模型出现后，文字生成有了很高商业价值，其融资标的可以参考图片类产品



市场规模测算

APB

企业发布“私域”岗位数同比增长率



说明: 1.取发布的岗位名称中直接带有“私域”的数据; 2.取发布的所有岗位总量;

数据来源: 前程无忧51Job


佐证1: 企业发布私域类型岗位同比大盘有更高增长率
前程无忧预测2024年私域运营岗位有150万人缺口



企业招募私域岗位薪资分布

APB

2019-2023年企业招募“私域”岗位月薪分布



说明: 岗位名称带“私域”字眼岗位, 企业发布时填写的岗位薪酬;

数据来源: 前程无忧51Job

在 2023 年企业发布岗位薪资范围中, 企业给出最多的月薪范围是 “6000-7999”元(占 26.81%), 和“8000-9999”元(占 20.44%)


可以证明, 企业招聘一名私域工作者, 一年将付出10万元左右成本





时间	企业数	用户数	备注
2016-2019 年	250 万	6000 万	企 业 微 信 发 布 于 2016 年 4 月
2020 年	550 万	4 亿	5 个 月 内 ， 用 户 数 增 4 倍 至 2.5 亿
2021 年	1000 万	5 亿月活	数 据 发 布 于 2022 年 1 月
2022 年	1200 万	5 亿日活	数 据 发 布 于 2023 年 3 月

截止2022年，使用企业微信的真实企业1200万家
客户达到5亿日活



- 1200万家运用企业微信的企业，按照30%比例经营企业私域，有360万家，按照每家平均有1运营人员，年成本12万元计算
 - 总成本在4320亿左右，按照未来AI替代率40%，且甲方控制成本在20%计算则市场规模为345.6亿
- 另一种佐证算法：目前私域日活5亿，按常规c端逻辑日活是月活60%，则私域月活约12.5亿
 - 私域人服比按照1:1000计算，则运营人员约125万人，年成本12万元计算
 - 总成本1500亿，如果增加预估招聘缺口，总成本约3000亿
 - 按照未来AI替代率40%，且甲方控制成本在20%计算则市场规模约240亿



- 总体而言，中性悲观预测私域AI智能体的市场规模在240-340亿左右
- 叠加私域后续的增长态势，3年内市场规模应该在500-700亿左右
- 假设做到3%的市场覆盖度，则年收入规模应该在10亿左右





用AI替代人工，
降低成本

用AI能力构建效
果更好的产品

用AI重新构建新
产品，覆盖已有
产品



用AI替代人工，降低
成本

-原有产品的价值替换

用AI能力构建效果更
好的产品

-新增价值

用AI重新构建新产品，
覆盖已有产品

-新增价值



用AI替代人工，降低
成本

-原有产品的价值替换

用AI能力构建效果更
好的产品

-新增价值

用AI重新构建新产品，
覆盖已有产品

-新增价值



新增价值-货币价值

APB



但老网红已经身价暴跌了

APB

仙人掌（普通电池款）

多首歌曲

- 1.生日快乐搞怪歌
- 2.DANCING POLISH COW
- 3.非洲鼓点音乐
- 4.CONGO
- 5.尼玛情歌
-

多种功能

- 1.学说话复读
- 2.多首歌曲
- 3.沙雕魔性抖舞
- 4.可录音15秒



88VIP 您有20元消费券待使用

距结束 3天23小时

仙人掌玩具学说话会跳舞唱歌婴儿学人玩偶复读网红六一儿童节礼物

可开发票

折后¥13 优惠前¥14.5
已售 62

百亿加补节

4月28日 24点 结束

官方立减1.5元

消费券

玩具天降券满550减50

购买得积分

配 送 48小时内发货, 预计后天送达 快递: 免运费 浙江金华 至 北京市 朝阳区

保障资质 大促价保 退货宝 假一赔四 极速退款 7天无理由退换 88VIP退货包运费

可选支付 信用卡支付

颜色分类



【电池款】跳舞仙人掌



【充电款】跳舞仙人掌



【升级四代】电池跳舞仙人掌



【USB直冲升级锂电】跳舞仙人掌



【USB直冲升级锂电】不发光款跳舞仙人掌



【USB直冲升级锂电】墨西哥跳舞仙人掌



【USB直冲升级锂电】橙色萨克斯太阳花



【USB直冲升级锂电】粉色萨克斯太阳花



【USB直冲升级锂电】圣诞跳舞仙人掌



【USB直冲升级锂电】黄帽跳舞仙人掌



【USB直冲升级锂电】围巾跳舞仙人掌



【USB直冲升级锂电】万向行走跳舞仙人掌

老网红+大模型=?

APB



+

deepseek

=





FoloToy AI仙人掌 Deep seek大模型对话玩具智能大模型生日礼物

超300人加购

券后¥398

优惠前¥538 · 已售 700+

商品券满398减140

配 送 48小时内发货 快递: 免运费 北京 至 北京 朝阳 ✓

保 障 7天无理由退货 88VIP退货包运费 ✓

可选支付 信用卡支付 ①

颜色分类



绿色 (6个月对话服务)



绿色 (12个月对话服务)

一年软件订阅服务 (不包含玩具本体)



AI仙人掌 (尊享版)

数 量 - 1 + 有货

加入购物车

领券购买

★
收藏

	原有产品	智能化改造
流量	CPM成本：45（模拟）	CPM成本：40（模拟）
转化价值	推广转化率:4%（模拟）	推广转化率：5%（模拟）
客单价价值	13	398
用户生命周期价值产品	无	100/年（订阅费用）
预估用户生命周期转化率	无	5%（模拟）
用户生命周期价值	13	$398 + 100 * 5\% = 403$




	原有产品	智能化改造
流量	CPM成本：45（模拟）	CPM成本：40（模拟）
转化价值	推广转化率:4%（模拟）	推广转化率：5%（模拟）
客单价价值	13	398
用户生命周期价值产品	无	100/年（订阅费用）
预估用户生命周期转化率	无	5%（模拟）
用户生命周期价值	13	$398 + 100 * 5\% = 403$

$$\begin{aligned}
 LTV/CAC &= \frac{\text{用户生命周期价值}}{\text{用户获取成本}} \\
 &= \frac{\text{用户生命周期价值}}{\text{用户获取成本} = \text{流量成本} / \text{转化率}}
 \end{aligned}$$



	原有产品	智能化改造
流量	CPM成本：45（模拟）	CPM成本：40（模拟）
转化价值	推广转化率:0.4%（模拟）	推广转化率：0.5%（模拟）
客单价价值	13	398
用户生命周期价值产品	无	100/年（订阅费用）
预估用户生命周期转化率	无	5%（模拟）
用户生命周期价值	13	$398 + 100 * 5\% = 403$
LTV/CAC	$13 / ((45 / 1000) / 0.4\%) = 1.16$	$403 / ((40 / 1000) / 0.5\%) = 50.4$

$$\begin{aligned}
 \text{LTV/CAC} &= \frac{\text{用户生命周期价值}}{\text{用户获取成本}} \\
 &= \frac{\text{用户生命周期价值}}{\text{用户获取成本} = \text{流量成本} / \text{转化率}}
 \end{aligned}$$



第二个常见场景

APB

- 在原有产品上，增加了一款新的AI产品或AI功能
- 计算其潜在价值



- 直接作为一个单独收费的模块
- 作为一个额外功能



直接作为一个功能模块

APB

- 预估
 - 转化率
 - 触达用户量
- 确定
 - 客单价
- 计算
 - 转化价值



在线导图 功能 图库 下载 购买 资源 用户

免费

¥ **0**

开始使用

包含:

- ✓ 一次性赠送 10次 AI 文本功能体验 限时福利
- ✓ 无限主题节点
- ✓ 丰富的骨架结构与文本样式
- ✓ 可创建10张在线导图
- ✓ 可演示5张幻灯片

Pro

¥ **380** / 年

立即升级

除所有免费功能外, 还有:

- ✓ 一次性赠送 100次 AI 文本功能体验 限时福利
- ✓ 万能的网格结构
- ✓ 智能自定义配色方案
- ✓ 插入数学方程、主题链接和附件
- ✓ 插入待办事项与语音备注
- ✓ SVG, markdown等10多种导出格式
- ✓ 可创建50张在线导图
- ✓ 可演示全部幻灯片

Pro+

¥ **420** / 年 ~~¥799~~

立即升级

除所有功能外, 还有:

- ✓ 专享 Xmind AI 全家桶功能 (持续上新) NEW
- ✓ 无限新建在线导图
- ✓ 无限分享与协作在线导图
- ✓ 导图协作者支持查看和编辑
- ✓ 实时同步协作者的视角, 在线交流更快捷
- ✓ 所有骨架、结构、文本、图形与配色样式
- ✓ 所有高阶的创作功能和快捷的操作技巧
- ✓ 持续解锁 Xmind 最新的产品功能
- ✓ 提供优先技术支持

- 假设

- pro用户量5w
- 转化率2%
- 新增价值40元/年
- 免费用户30w
- 转化率0.1%
- 新增价值420元/年

- 则AI新产品带来的价值为： $5*2\%*40+30*0.1\%*420=16.6w$



Part Four

04

总结

构建一个AI产品的步骤

APB

需求挖掘

解决AI从哪里入手的问题

价值评估

判断这样做值不值的问题

智能构建

解决AI产品设计问题

产品架构

决定AI产品能力和适应性问题

产品实施


解决AI产品落地问题

商业策略

解决AI产品赚钱问题

测试调优

解决AI产品精度和后续提升问题



- 基于已有产品或业务的链路，进行脑力层人力替代
 - 降低成本
- 基于场景建立新的产品或链路，达成更好效果
 - 提升效益





估算人力单
步成本

估算AI
Token成本

测算成本差
值



每次使用的
token成本

设计开发测试
的人力成本

训练和数据成本



成本质量
平衡

中文环境
落地特质

产品演进

防止踩坑



- 根据产品的发展阶段，采用不同的模型使用策略

验证

发展

成熟



	原有产品	智能化改造
流量	CPM成本：45（模拟）	CPM成本：40（模拟）
转化价值	推广转化率:4%（模拟）	推广转化率：5%（模拟）
客单价价值	13	398
用户生命周期价值产品	无	100/年（订阅费用）
预估用户生命周期转化率	无	5%（模拟）
用户生命周期价值	13	$398 + 100 * 5\% = 403$

$$\begin{aligned}
 LTV/CAC &= \frac{\text{用户生命周期价值}}{\text{用户获取成本}} \\
 &= \frac{\text{用户生命周期价值}}{\text{用户获取成本} = \text{流量成本} / \text{转化率}}
 \end{aligned}$$



模型微调成本-参考要素

APB

模型选择

基础模型大小

预训练语料库的范围与深度

微调数据集

数据量

数据处理

微调次数和迭代

训练周期

实验次数

计算资源

GPU、TPU使用数量和时长

存储和贷款费用

技术支持

专家支持

定制开发

用AI替代人工，降低
成本

-原有产品的价值替换

用AI能力构建效果更
好的产品

-新增价值

用AI重新构建新产品，
覆盖已有产品

-新增价值



- 计算2-2作业中单次工作使用的token数量
 - 计算使用不同大模型底座的分别成本
 - Doubao
 - Deepseek
 - 计算其中图片生成的token和成本
- 确认总成本



- 2-10 大模型产品增长策略



智在必得

Thanks for having you all the way

